

Shomer.AI — תכנית עסקית

סטטוס: עודכן 2026-05-30 לאחר נעילת הארכיטקטורה (Phase 0 + מסמך החלטות מפגש 4) · מנחה: ד"ר יורם סגל
גרסה קודמת: טיוטה למפגש 3 · 2026-05-27 (Markdown מקבילה ל-LaTeX ב-business_plan.tex). **שינויים מהותיים בגרסה זו:** עדכון 5\$ (תמחור מומלץ 29.90\$ במקום 40\$), שכתוב 6\$ (כלכלת טוקנים — GPT-4o-mini במקום Haiku, עלות נמוכה פי 7.7), הוספת 7\$ (אלטרנטיבת שרת מקומי \$50K), הוספת 8\$ (סיכום רווחיות מפורט).
הערות מקורות: מספרים מאומתים מלווים בקישור; מספרים שטרם אומתו מסומנים [למקור]. שער חליפין משוער: 1 USD ≈ 3.6 ILS.

מערכת AI בעברית להגנה על ילדים מפני בריונות, איומים, תכנים מיניים ומצוקה רגשית מקוונת — מתוך השיחה וההקשר שלה.

1. תקציר מנהלים (Executive Summary)

הבעיה. ילדים ובני נוער דוברי עברית חשופים יום-יום לבריונות מקוונת, איומים, תכנים מיניים לא רצויים ושיח אובדני. הכלים הקיימים בשוק בנויים בעיקר לאנגלית, מבוססים מילות-מפתח שטחיות, **שופטים הודעה בודדת בלי הקשר**, ואינם מבינים את ההקשר התרבותי-לשוני הישראלי — מה שמוביל להצפת התראות-שווא (Alert Fatigue) ולנטישת המוצר תוך ימים.

הפתרון. Shomer.AI הוא "שומר דיגיטלי שקט" להורים: מסווג חזית עברי (DictaBERT) מהיר וזול המאתר סיכון, ומעליו **סוכן הקשר** (Context Agent, GPT-4o-mini) שמאמת כל מקרה גבול לפני שליחת התראה — וכך **חותך את אחוז ההתראות-שווא** משמעותית. כל התראה להורה מלווה בהסבר, ציטוט וסוג הסיכון (Explainable AI).

המשתמש. הורים לילדים בגילי 6–16 בישראל; בהמשך — יועצים חינוכיים וארגוני בטיחות ילדים.

הערך והרווחיות. מבנה עלות היברידי + בחירה ב-GPT-4o-mini ל-Context Agent מובילים לעלות זניחה של ~0.27\$ למשתמש בחודש (=99%+ שולי-תרומה). תמחור מומלץ של 29.90\$ **חודש** ממקם את המוצר תחרותית מול Canopy (\$7.99) ועם פרמיה צנועה על Bark (\$2.42 לאנגלית בלבד), תוך שמירה על שולי רווח גבוהים מאוד.

2. שוק (TAM / SAM / SOM)

קהל היעד: הורים לילדים בגילי 6–16 בישראל.

שכבה	היקף	הסבר ומקור
TAM	שוק ה-Parental Control העולמי $\approx \$1.55\text{B}$ – 1.74B (2025–2026), CAGR $\approx 9.8\%$ – 12.3%	אומדנים: $\backslash$; (Global Growth Insights) $\rightarrow \$1.55\text{B}$ $\rightarrow \$1.74\text{B}$ (Future Market Insights) CAGR 9.8%.
SAM	$\approx 1.5\text{M}$ בתי-אב דוברי-עברית עם ילדים בגיל הרלוונטי	בישראל $\approx 2.25\text{M}$ משפחות, כמחציתן זוג הורים עם ילד עד גיל 17 (הלמ"ס / JNS). פילוח מדויק לגילאי 6–16 בעלי סמארטפון [למקור].
SOM	שנה ראשונה: 5,000 משתמשים פעילים, ARPU מומלץ $\backslash$ חודש/חודש 29.90 (היה $\backslash$ חודש/חודש 40 בגרסה קודמת)	יעד חדירה ריאלי — 0.33% מ-SAM. תמחור מותאם אחרי ניתוח עלויות והשוואה תחרותית מעודכנת ($\backslash$ 5).

3. מתחרים (Competitors)

מתחרה	מחיר (מאומת)	ערך / חוזקה	חולשה מרכזית
Bark (ארה"ב)	$\backslash$ חודש/חודש 2.42 = $\backslash$ שנה (1 מכשיר) 29 =	כיסוי רחב, סריקה רב-מודאלית	אנגלית בלבד — לא מזהה סיכון בעברית
Qustodio (ספרד)	חינמי / $\backslash$ חודש/חודש 54.95 / $\backslash$ שנה 99.95	כיסוי קרוס-פלטפורמה, דשבורד מקיף	AI מבוסס מילות-מפתח, ללא ניואנס ישראלי
Canopy (ארה"ב)	$\backslash$ חודש/חודש 7.99 (3 מכשירים, שנתי) (מקור)	חסימת תוכן מיני בזמן-אמת	ממוקד עירוס בלבד, לא בריונות/שיח
Keepers (ישראל)	ניסיון 14 יום; $\backslash$ חודש/חודש 19.90 — 39.90 $\backslash$ חודש/חודש (אומדן) [למקור]	ניתוח רגשי, מודעות לפרטיות	סלנג ישראלי בעייתי (הצהרת CEO); ללא LLM מודרני
Bosco (ישראל)	$\backslash$ חודש/חודש 29.90 (אומדן) [למקור]	מגן-פרטיות, חכם פסיכולוגית	אינדיקציה איטית — מאתר אחרי הפגיעה
★ Shomer.AI	29.90 $\backslash$ חודש/חודש מומלץ ($\approx \$8.30$)	עברית-ראשון, סוכן-הקשר, Explainable, פרטיות מלאה	מוצר חדש — ללא נתח שוק קיים

מיקום תחרותי: $\backslash$ חודש/חודש 29.90 מציב אותנו במרכז הטווח הישראלי (זוהה ל-Bosco, גבוה ב-50% מ-Keepers, מקביל ל-Canopy). אנו לא מנסים להיות הזולים — אנו מציעים ערך ייחודי (עברית-ראשון + Context Agent) שאין במוצר אחר בשוק הישראלי.

4. ייחוד תחרותי (USP)

ה-USP במשפט אחד: Shomer.AI היא מערכת ההגנה היחידה על ילדים שהיא עברית-ראשון, מבצעת את הסיווג מקומית (פרטיות מלאה לטקסטים), ומודעת-הקשר — ומשתמשת בסוכן-הקשר מבוסס-LLM כדי לחתוך

ארבעת עמודי הייחוד :

1. **עברית-ראשון**. Bark עובד באנגלית בלבד ; Keepers מודה שסלנג ישראלי לא נפתר. Shomer.AI מאומן על DictaBERT (encoder עברי), SinaLab Offensive-Hebrew + נתונים סינתטיים של סלנג נוער עכשווי.
2. **מקומי בחזית, ענן רק על מקרי גבול**. רוב הסיווג רץ מקומית = פרטיות + עלות נמוכה. רק 15% מהתעבורה (מקרי גבול) נשלחת ל-GPT-4o-mini לreasoning, ללא PII.
3. **מודע-הקשר**. המערכת שופטת את ההודעה לאור **השיחה כולה** (5 תורים אחרונים) — לא הודעה בודדת. לב התרומה המחקרית.
4. **הקשר + הסבר**. סוכן-ההקשר מאמת לפני התראה (פותר את בעיית ה-False Positives), וכל התראה מלווה בהסבר וציטוט.

5. מודל הכנסות (Revenue Model) — עודכן

מודל Freemium :

- **שכבת Free בסיסית** — סיווג חזית בלבד (ללא Context Agent), עד 5 התראות ביום. מטרתה אימוץ והפצה אורגנית.
- **מנוי הורה בתשלום (Premium)** — סוכן ההקשר המלא, התראות חכמות עם הסבר וציטוט, OCR לצילומי מסך, דשבורד הורה, היסטוריה והפניה למשאבי-סיוע.

ניתוח 3 תרחישי תמחור

תרחיש	מחיר חודשי	מיקום תחרותי	משתמשים צפויים (שנה 1)	הכנסה שנתית	המלצה
A — חודר אגרסיבי	19.90 ₪ (~\$5.50)	זול מ-Keepers, מתחת ל-Canopy	~8,000 (גמישות גבוהה)	1.91M ₪	❌ מותיר ערך על השולחן
B — מומלץ	29.90 ₪ (~\$8.30)	תואם Bosco, פרמיה מעל Keepers	~5,000 (יעד SOM)	1.79M ₪	✅ שווי-מיטבי
C — פרמיום	39.90 ₪ (~\$40)	יקר מ-Canopy ו-Bosco	~3,500 (גמישות שלילית)	1.68M ₪	⚠️ סיכון לאיבוד נתח שוק

הבחירה: תרחיש B (29.90 ₪/חודש). מקסם הכנסה צפויה תוך שמירה על מיקום תחרותי בריא ולא להגזים מול המתחרים הישראלים.

תרחיש SOM להמחשה (שנה ראשונה — 29.90₪)

פרמטר	ערך	הערה
משתמשים משלמים	5,000	יעד חדירה (סעיף 2)
ARPU	29.90₪ / חודש	תמחור מומלץ (תרחיש B)
הכנסה חודשית (ברוטו)	149,500₪	$5,000 \times 29.90₪$
הכנסה שנתית (ברוטו)	1,794,000₪	$12 \times 149,500₪$
שולי-תרומה צפויים	~99%	ראו 6\$ — עלות משתנה ~0.27₪/משתמש/חודש

6. מבנה עלויות — מודל ענן (GPT-4o-mini)

הנוסחה הכללית

$$\text{Variable Cost} = \text{users} \times \text{calls} \times (\text{input} + \text{output tokens}) \times \text{model_price} \times \text{agent_multiplier}$$

כאשר `agent_multiplier` מגלם תכנון + קריאות-כלים + ניסיונות-חוזרים ($\approx 1.5-3$).

היתרון המבני של הארכיטקטורה שנבחרה

הסיווג בחזית רץ ב-DictaBERT-base מקומי על CPU → עלות-טוקן $\approx 0.1\$$. עבור ~85% מההודעות (מסומנות "ירוק" או "אדום" בביטחון גבוה) — אפס עלות ענן. העלות נוצרת רק מ-15% מקרי-הגבול שעולים ל-GPT-4o-mini. זהו יתרון מבני מוחלט מול מתחרים שמשלמים על כל הודעה (Bark, Qustodio).

חישוב מפורט עם נתוני SOM (5,000 משתמשים)

הנחות עבודה: - 5,000 משתמשים $\times$ 30 הודעות נסרקות ביום $\times$ 30 ימים $\Rightarrow$ 4.5M הודעות/חודש - סיווג מקומי על כל ההודעות (DictaBERT, CPU): עלות-טוקן $\approx 0.1\$$ - 15% מהתעבורה מגיעה לסוכן-ההקשר $\Rightarrow$ 675K קריאות LLM/חודש - לקריאה ממוצעת: 700 טוקני קלט + 300 טוקני פלט = 1,000 טוקנים, $\text{agent_multiplier}=2$ (planning + tools + retries) - מודל ראשי: GPT-4o-mini (0.15\$ קלט / 0.60\$ פלט ל-1M טוקנים) (מקור)

חישוב לקריאה (GPT-4o-mini):

$$\begin{aligned} & (700 \times \$0.15 + 300 \times \$0.60) / 1M \times \text{multiplier } 2 \\ &= (\$0.000105 + \$0.00018) \times 2 \\ &= \$0.00057 \text{ לקריאה} \end{aligned}$$

עלות חודשית כוללת:

$675,000 \text{ calls} \times \$0.00057 = \sim \$385/\text{חודש}$, $\approx 1,386$

עלות לאינטראקציה (מפוזרת על כל 4.5M ההודעות):

$\$385 / 4.5M = \0.0000855 , ≈ 0.0003 לאינטראקציה

זה פי 58 מתחת ליעד $\$0.005$ /אינטראקציה שהוגדר ב- $\$11.3$ proposal.

השוואה: GPT-4o-mini מול Haiku 4.5 (fallback)

מודל	עלות/קריאה	עלות חודשית SOM	סה"כ לשנה
GPT-4o-mini (primary)	\$0.00057	\$385 (≈1,386)	\$4,620 (≈16,632)
Claude Haiku 4.5 (fallback)	\$0.0044	\$2,970 (≈10,692)	\$35,640 (≈128,304)

אסטרטגיית test-cheap-first: מתחילים ב-GPT-4o-mini. אם מפגש 8 (gold set) יראה שזה לא מספיק → עוברים ל-Haiku, ועדיין מתחת לתקציב.

עלויות תשתית קבועות (נדרשות ללא קשר לנפח)

פריט	עלות חודשית	הערה
שרת ענן בסיסי (FastAPI + DictaBERT) — DigitalOcean/Hetzner	≈200 (\$55~)	4 vCPU + 8GB RAM ; \$50/חודש ; מספיקים ל-5K משתמשים
FCM (push notifications)	0	חינם ל-5K משתמשים, \$0.50 ל-1M הודעות מעבר לכך
אחסון לוגים (Audit Log)	≈50	SQLite מקומי על השרת, גיבוי שבועי ל-S3
ניטור + תקשורת	≈150	Sentry / Better Stack בסיסי
סה"כ תשתית קבועה	≈400~	חודש

עלות סופית למשתמש ב-SOM

עלות משתנה: $\approx 1,386 / 5,000$ משתמשים = ≈ 0.28 /משתמש/חודש
עלות קבועה: $\approx 400 / 5,000$ משתמשים = ≈ 0.08 /משתמש/חודש
סה"כ עלות: ≈ 0.36 /משתמש/חודש

שולי-תרומה (Contribution Margin):

margin עלות (≈ 0.36) = ≈ 29.54 /משתמש/חודש = 29.90 (ARPU) - 98.8%

7. אלטרנטיבה: שרת מקומי על-ה-(\$50K) Premises

עבור גדילה משמעותית או דרישות פרטיות מוגברות (שיווק לבתי ספר, ארגוני בטיחות), קיימת אלטרנטיבה: **שרת חזק מקומי שמריץ גם את ה-Context Agent locally** (DictaLM 2.0 דרך Ollama במקום GPT-4o-mini).

תצורת חומרה מוצעת

רכיב	מפרט	עלות (USD)
GPU	NVIDIA H100 80GB (או $2 \times A100$)	\$30,000
CPU	AMD Threadripper / Xeon (32 cores)	\$4,000
RAM	256GB ECC	\$2,500
Storage	4TB NVMe SSD + 16TB HDD (gold set + לוגים)	\$2,500
מארז + ספק כוח	1600W Server-grade chassis + PSU	\$2,000
Networking + Cooling	רשת 10G + מערכת קירור	\$3,000
תוכנה + leftover	Ubuntu + setup + spare parts	\$6,000
סה"כ חד-פעמי		~\$50,000 (\$180,000~)

עלויות תפעול חודשיות

פריט	חישוב	עלות חודשית
פחת חומרה	$\$50K \div 60$ (חודש 5 שנים)	\$833 (₪3,000~)
חשמל — שרת	$1kW \times 720 \text{ שעות} \times \$0.15/kWh$	\$108 (₪389~)
חשמל — קירור	$\sim 30\%$ מצריכת השרת = $300W \times 720 \times \$0.15$	\$32 (₪115~)
תחזוקה + חלקי חילוף	$\sim \$50/\text{חודש}$ בממוצע	\$50 (₪180~)
חיבור אינטרנט business-grade	סיב 1Gbps + IP סטטי	\$80 (₪288~)
סה"כ חודשי		~\$1,103 (\$3,972~)

קיבולת — כמה משתמשים שרת אחד יכול לשרת?

- DictaBERT (frontline): CPU-bound, throughput של 5,000 + req/sec — בעיניים סגורות מתאים ל-100K משתמשים
- OCR (Tesseract): ~50 תמונות/שנייה ל-CPU core — לא צוואר בקבוק
- Context Agent (DictaLM 2.0 על H100): ~5-8 שניות/קריאה → throughput של 8-12 קריאות/דקה לכל GPU
- $8 \times 345,600 = \sim 2,764,800$ calls/min × 60 × 24 × 30 = משתמשים מקסימום
- ב-15% borderline = יכול לטפל בעד ~75,000 משתמשים פעילים

- צוואר הבקבוק האמיתי = ה-Context Agent. השרת תוכנן ל-~15K-10K משתמשים בנוחות (עם רזרבה לעומסי peak).

השוואה: ענן מול שרת מקומי בסקיילים שונים

משתמשים	עלות ענן/חודש	עלות שרת מקומי/חודש	מי זול יותר?	חיסכון שנתי
5,000 (SOM)	1,386 ₪	3,972 ₪	ענן	31K ₪ לטובת ענן
10,000	2,772 ₪	3,972 ₪	ענן (במעט)	14K ₪ לטובת ענן
13,000 (breakeven)	3,604 ₪	3,972 ₪	שווה כמעט	5K > ₪ הפרש
20,000	5,544 ₪	3,972 ₪	מקומי	19K ₪ לטובת מקומי
50,000	13,860 ₪	3,972 ₪ (שרת אחד עדיין מספיק)	מקומי	119K ₪ לטובת מקומי
100,000	27,720 ₪	7,944 ₪ (2 שרתים)	מקומי	237K ₪ לטובת מקומי

נקודת השבירה (Breakeven) ו-ROI

נקודת שבירה: ~13,000 משתמשים פעילים.

ROI על השקעת ה-180K (₪50K) : - ב-30K משתמשים : חיסכון 50K ₪/שנה → $\text{payback} \sim 3.6$ שנים - ב-50K משתמשים : חיסכון 119K ₪/שנה → $\text{payback} \sim 1.5$ שנים - ב-100K משתמשים : חיסכון 237K ₪/שנה → $\text{payback} \sim 0.9$ חודשים

יתרונות נוספים מעבר לעלות

1. פרטיות מלאה — שום נתון לא עוזב את ישראל. טיעון שיווקי חזק לבתי ספר ו-B2B.
2. שליטה במודל — אפשר fine-tune מותאם בלי לחכות ל-OpenAI/Anthropic.
3. חסינות לשינויי מחירים בענן — נעילת עלות צפויה לחומש.
4. תמיכה ב-air-gap deployments — לקוחות רגישים (צה"ל, חברות בריאות).

חסרונות / סיכונים

1. השקעה גדולה מראש — 180K ₪ שאסור לטעות עליה.
2. תחזוקה דורשת ידע מערכות — לא רק קוד.
3. DictaLM 2.0 מקומי איכותו פחות מ-GPT-4o-mini (אומדן : 0.75 vs 0.80 על reasoning עברי) — לא בדוק.
4. scalability — שרת שני דורש replication ולוגיקת load-balancing.

המלצה אסטרטגית

שלב גדילה	אסטרטגיה
שנה 1 (0–5K משתמשים)	ענן בלבד (GPT-4o-mini). פשוט, זול, סקייבלילי.
שנה 2 (5K–13K)	ענן עיקרי + פיילוט שרת מקומי (תרומה: לבנות מומחיות, להציע B2B/בתי ספר ב-on-premise).
שנה 3 (+13K)	שרת מקומי ראשי + ענן fallback. מעבר הדרגתי.
גם בתי ספר / B2B	שרת מקומי מההתחלה — ה-USP של "data stays in Israel" שווה הרבה.

8. סיכום רווחיות (Profitability Summary)

תשובה ישירה ל-3 השאלות:

שאלה 1: מה תהיה העלות החודשית של המוצר?

Scale	סוג תשתית	עלות חודשית כוללת	עלות למשתמש
SOM (5K משתמשים)	ענן (GPT-4o-mini) + שרת בסיסי	1,786 ₪/חודש	0.36 ₪
10K משתמשים	ענן + שרת בסיסי משודרג	3,200 ₪/חודש	0.32 ₪
30K משתמשים	מעבר לשרת מקומי	3,972 ₪/חודש (קבוע)	0.13 ₪
100K משתמשים	2 שרתים מקומיים	7,944 ₪/חודש	0.08 ₪

מסקנה: עלות שולית לקטן מ-0.50₪/משתמש בכל סקייל. הרווח שלנו נקבע על-ידי תמחור, לא על-ידי עלות.

שאלה 2: כמה לגבות מהמשתמשים כדי לקבל רווח מקסימלי בלי להגזים?

29.90₪ לחודש — המומלץ הסופי.

הצדקה: - תחרותית: זהה ל-Bosco (29.90₪ אומדן), פרמיה צנועה מעל Keepers, מתחת ל-Bark לרב-מכשירי - מצדיקה את הערך: הפרמיה מעל (29₪ ≈ \$7.99) Canopy זניחה ומוצדקת ע"י עברית-Context Agent + first - לא יקרים: ב-3 הפעמים זול יותר מ-Bark משפחתי (95.90\$/שנה = 288₪/שנה) - משאירה מרווח לפרמיום בעתיד: "Shomer.AI Family" עתידי ב-49.90₪/חודש ל-3+ ילדים

מקסום רווח מעל 40₪: טכנית, התמחור הקודם 40₪ נתן הכנסה מקסימלית בהנחת 5,000 משתמשים. אבל במחיר זה גמישות הביקוש שלילית — ב-10%-20% יותר נמוך נצפה לעלייה משמעותית בהקבלה. 29.90₪ מקסם את ה-Net Revenue הצפוי.

שאלה 3: ענן או שרת מקומי?

בקצרה — שלוש תקופות:

שנה 1 (13-0K): ענן → GPT-4o-mini
שנה 2 (פיילוט): ענן עיקרי, שרת מקומי בפיילוט
שנה 3 fallback שרת מקומי ראשי + ענן (13K+):

ROI ההשקעה של payback - \$50K: ב-30K משתמשים: 3.6 שנים - payback ב-50K משתמשים: 1.5 שנים

חוץ מעלות: השרת המקומי הופך לערך שיווקי לפרמיום (B2B/בתי ספר/לקוחות פרטיות) שלא ניתן לשחזר בענן.

תרחיש רווח לשנה ראשונה (29.90\$, 5K משתמשים, ענן)

הכנסה שנתית: ₪1,794,000
פחות עלויות תפעוליות:
- תשתית (משתנה + קבוע): -₪21,000 (12 × ₪1,786)
- שיווק (40% מההכנסה): -₪717,600
- תמיכה (1 איש): -₪180,000
- (בשנה 1 dev) פיתוח: -₪360,000
- יועצים + שונות: -₪100,000
EBITDA ~₪415,400: (~23% margin) צפוי שנה 1:

שנה 2 (29.90\$, 15K משתמשים, עוברים למקומי): - הכנסה: 5,382,000 ₪ - עלויות נטו: ~2,500,000 ₪ - EBITDA: ~2.88M (~53% margin) ← נקודת המעבר לרווחיות בריאה

9. סיכונים פיננסיים ומיטיגציות

סיכון	סבירות	חומרה	מיטיגציה
המחירים של OpenAI יעלו +50%	בינונית	בינונית	החלפה ל-Haiku/Gemini Flash ; בסקייל — מעבר למקומי
Conversion ל-Premium נמוך מהצפוי (פחות מ-20% מהחשיפה)	גבוהה	גבוהה	freemium אגרסיבי ; שיפור UX של ה-onboarding
Churn גבוה בגלל FP rate (>3 התראות שווא/יום)	בינונית	קריטית	ניטור FP בproduction ; אם גבוה — חיזוק Context Agent (מעבר ל-Haiku)
תחרות חדשה תיכנס לעברית	בינונית	גבוהה	ל-Bark/Qustodio לא משתלם לפתח עברית בלעדית ; הסיכון העיקרי הוא Keepers/Bosco — מטפלים ע"י איכות עליונה
GDPR / רגולציה ישראלית להגנת קטינים	בינונית	גבוהה	7 retention ימים קשיחה ; ללא PII בענן ; תיעוד עיצוב פרטיות
הוצאה על השקעת \$50K לא חוזרת	נמוכה (רק אם נחליט בשנה 2-3)	בינונית	החלטה דחויה עד שנדע ש-13K+ משתמשים בטוחים

מסמך זה הוא טיוטה למפגש 4 (31/05/2026). שינויים מהותיים מהגרסה למפגש 3 : - 5\$: תמחור מומלץ ירד מ-40\$ ל-29.90\$ לפי ניתוח גמישות ביקוש ומיקום תחרותי - 6\$: שכתוב מלא — מחירי GPT-4o-mini (זול פי 7.7 מ-Haiku שהיה בגרסה הקודמת) - 7\$ חדש : אלטרנטיבת שרת מקומי \$50K עם ניתוח breakeven מלא - 8\$ חדש : סיכום רווחיות שעונה ישירות לשאלות "כמה זה עולה" ו"כמה לגבות"

מספרים המסומנים [למקור] או "אומדן" דורשים השלמת מקור לפני הגרסה הסופית.