

Shomer.AI — טכניקות עיבוד נתונים לסיווג עברית

(DictaBERT)

מסמך: מדריך טכניקות לעיבוד נתונים — אילו טכניקות יש, מה כל אחת עושה, איך היא עוזרת ל-F1 / latency, מתי לשלב, מתי לסכן. **משלים את:** [dictabert_classifier_architecture.md](#) (תכנון הרשת) · [bullying_data_he.md](#) (אסטרטגיית מקורות הנתונים) **סטטוס:** טיוטה למפגש 5 · 2026-06-03 **שימוש:** הברייף ל-ai-researcher-developer שיכתוב training/prepare_data_dictabert.py מסתמך ישירות על המסמך הזה.

1§ · תקציר מנהלים

יש לנו **עשרות טכניקות נתונים** שיכולות לשפר את F1 או לזרז את האימון/inference. בפועל — לא כולן בטוחות יחד. המסמך הזה:

- ממפה את **כל הטכניקות** שדנו בהן, בקבוצות לפי מטרה (ניקוי / יעילות / איזון / Split / augmentation).
- מסביר **מה כל טכניקה עושה** מבחינה מכאנית, ואיך היא עוזרת.
- מנתח **בטיחות שילוב** — אילו טכניקות "מתכפלות" ויוצרות over-correction, ואיך למנע.
- מתעד **מסלול הרחבה** — מה אפשר להוסיף בעתיד למפגשים 6–8 כדי להגיע ל-best score.

הסטאק הסופי למפגש 5 (כפי שסוכם — "option 2"): A1-A7 (ניקוי מלא) + B1-B3 (יעילות) + C2 (Focal Loss) עם משקלי מחלקות מובנים) + E1+E2+E3 + D1-D4 (Split discipline) + C4 (label smoothing $\epsilon=0.05$) EDA קל על מחלקות מיעוט בלבד, פי-2 augmentation). **לא** משלבים C1 בנפרד (subsumed by C2), C3 (sampler — שמור ל-fallback), E4 (synonym replacement — חלש בעברית), ו-F1-F8 (נדחים למפגשים 6–8).

2§ · קבוצה A — ניקוי ושלמות נתונים (Foundation)

קבוצה זו אחראית על איכות הקלט. כל הטכניקות פה **בטוחות יחד** (אדיטיביות) ועושות אך טוב.

#	טכניקה	מה היא עושה (מכאנית)	איך היא עוזרת	סיכון אם מוגזם
A1	Exact deduplication	Hash על כל זוג (text, label) ; שמירת רק unique-keys	מונע נזילה בין train/test — לפעמים אותו ציוץ מופיע מתווג זהה גם ב-train וגם ב-test → F1 מנופח	אין ; deterministic
A2	Near-dedup (MinHash, Jaccard ≥ 0.85)	חישוב MinHash signatures ; חיפוש זוגות עם Jaccard score $\leq$ סף ; הסרת כפילות לפי סף	SinaLab מכיל retweets ו- quote-tweets שלא נתפסים ב-A1	סף נמוך מדי (0.6) מוחק paraphrazים לגיטימיים
A3	NFKC Unicode normalization	מיפוי תווים לצורה הקנונית (לדוגמה : צורות הצגה ערביות → עברית סטנדרטית)	מקטין vocab fragmentation → ה- tokenizer מוצא את ה- WordPieces הנכונים יותר פעמים	בטוח לחלוטין ; תוכנן לזה
A4	הסרת ניקוד (nikud)	regex סטריפ של תווים א-ת ; (Hebrew diacritics)	בציאט/רשתות כמעט אף פעם לא יש ניקוד ; נוכחות ב-train + העדרות ב-inference = train-test mismatch	אין לדומיין שלנו (ניקוד נדיר במדיה דיגיטלית)
A5	ניקוי תווי כיוון בלתי-נראים (U+200E LRM, U+200F RLM, U+202A-E)	regex סטריפ של direction-control characters	נוצרים בהעתק-הדבק ; ה- tokenizer רואה אותם כ- junk → vocab pollution	אין
A6	החלפת URL/Mention ב-placeholders ([URL] , [MENTION])	regex matching של URLs (https://...) ו-mentions (@[w_]+) ; החלפה לטוקן placeholder	מונע למידה זיהוי-ספציפי אך שומר על האות הסטרוקטורלי "הייתה כאן הזכרה"	מחיקה במקום החלפה = איבוד אות ; חובה להחליף, לא למחוק
A7	Outlier filter (תווים > 3 או < 200 טוקנים)	סינון לפי אורך אחרי tokenization	מסיר שורות בודדות עם emoji או cookie-text שלא ניתן ללמוד מהן	יותר מדי אגרסיבי = הפסד דוגמאות קצרות אינפורמטיביות

שילוב A1-A7 : בטוח לחלוטין. כל הטכניקות אדיטיביות ; הקלט אחרי A7 הוא תת-קבוצה ניקה של הקלט המקורי.

3§ · קבוצה Sequencing & Efficiency — B

קבוצה זו לא משנה את התנהגות המודל — היא רק מזרזת את האימון/inference. **בטוחה לחלוטין** עם שאר הקבוצות.

#	טכניקה	מה היא עושה	איך היא עוזרת	סיכון
B1	Smart <code>max_length</code> מ- percentile	מדידת p99.5 של אורך טוקן ב-train set; הגדרת <code>max_length = p99.5</code>	Attention הוא $O(n^2)$; חצי אורך = פי 4 מהיר. עבור p99.5 — SinaLab הקטנת <code>max_length</code> מ-128 ל-96 $\approx 2 \times$ מהיר עם 0.5% truncation	חיתוך $< 0.5\%$ מהמקרים = פגיעה ב-F1
B2	Dynamic padding לפי batch	במקום padding ל- <code>max_length</code> הגלובלי, padding לאורך ה-sample הארוך ביותר בכל batch	20-30% מהיר יותר ל-epoch; אין הפסד מידע	אין
B3	Pre-tokenize once → Arrow cache	רוץ tokenizer פעם אחת על כל הדאטה, שמור כ-HF Dataset (Arrow format); השתמש כל epoch	מבטל overhead של ~10% מ-train time	Cache invalidation אם משנים את ה- tokenizer
B4	Truncation strategy = "longest_first"	בקיצוץ, שמירת תחילת הטקסט (לא מתיחה אחיד מ-2 הצדדים)	בציוצים, ה-punchline בדרך כלל בהתחלה; שומר רוב האות לתוויות הקשות	במקרים נדירים הסיגנל בסוף — נסיגה לאחר אבל לא דרמטית

שילוב B1-B4: בטוח לחלוטין. אין תלות בין הטכניקות.

§4 · קבוצה C — תיקון Class Imbalance

הקבוצה הכי קריטית למודל הצלחת — SinaLab הוא ~60% non_offensive, עם violence ו-pornographic נדירים מאוד (~2-1% כל אחד). כאן מתחיל סיכון השילוב.

#	טכניקה	מה היא עושה	איך היא עוזרת	סיכון
C1	Class-weighted cross-entropy	הכפלת loss לכל דוגמא ב- <code>weight[class_id]</code> ; המשקלים מ- <code>sklearn.compute_class_weight("balanced")</code>	אומר ל-optimizer "miss" על דוגמת violence הוא פי X חמור"	משקלים אגרסיביים ($\times 10$) $\rightarrow$ overfit למחלקות נדירות
C2	Focal Loss ($\gamma=2$) (Lin 2017)	$FL = -(1-p_t)^\gamma \cdot \log(p_t)$ — down-weights confident-correct predictions	מחזיר את ה-gradient לדוגמאות קשות, ללא קשר לתדירות. עוזר ל-rare AND-hard	γ גבוה (< 5) = "ratcheting" של gradient על דוגמאות לקויות-תיוג
C3	Class-balanced sampler	sample mini-batches כך שכל מחלקה מיוצגת שווה בכל batch	פתרון של ה-imbalance ב-input side (בניגוד ל-C1/C2 שעובדים ב-loss side)	בשילוב עם C1+C2 = triple correction; overprediction של מיעוטים ב-inference
C4	Label smoothing ($\epsilon=0.05$) (Szegedy 2016)	החלפת <code>[0,0,1,0,0]</code> ב- <code>[0.95, 0.0125, 0.0125, 0.0125, 0.0125]</code>	מקטין confidence ; excess calibration (ECE קטן)	שילוב עם Focal Loss = compound softening ; שמור $\epsilon=0.05$ נמוך

4.1§ · האסטרטגיה: C2 עם משקלים מובנים + $\epsilon=0.05$ C4

ב-Lin 2017, ה-Focal Loss מוגדר עם פרמטר `alpha` שאפשר להגדיר כ- `class_weights`. השילוב הזה הוא מנגנון אחד (לא שניים), שמטפל ב-rare-class detection וגם ב-hard-example focus.

```
class FocalLoss(nn.Module):
    def __init__(self, alpha: torch.Tensor, gamma: float = 2.0, label_smoothing: float = 0.0):
        # alpha: per-class weight tensor of shape (num_classes,)
        super().__init__()
        self.alpha = alpha
        self.gamma = gamma
        self.label_smoothing = label_smoothing

    def forward(self, logits, targets):
        ce = F.cross_entropy(
            logits, targets,
```

```

weight=self.alpha,
label_smoothing=self.label_smoothing,
reduction="none",
)
pt = torch.exp(-ce) # softmax probability of the true class
focal = (1 - pt) ** self.gamma * ce
return focal.mean()

```

זה ה-loss המומלץ למפגש 5.

5§ · קבוצה D — Splitting & Evaluation Discipline

#	טכניקה	מה היא עושה	איך היא עוזרת	סיכון
D1	Stratified split	<code>sklearn.train_test_split(stratify=labels)</code>	פיצול עם שמירת היחס הקבוע של כל מחלקה בכל split	אין
D2	Cross-split near-dedup check	אחרי הפיצול, רן MinHash A2 בין splits ; הצדקת כשל אם near-dup נמצא זוג	מבטל את ה-F1--F1 inflation bug הנפוץ ביותר	אין
D3	Style-stratified holdout (1040 משפטים)	שמירת כל הדאטה של <code>data/ocr_validation/sentences.jsonl</code> ל-evaluation בלבד ; דיווח F1 לפי A/B/C/D style	מספק טבלת robustness — F1 clear / code-switching / poor-spelling / children-mistakes בנפרד	אין ; bonus pure
D4	Holding test split untouched	רק test set אחד ב-Meeting 5 ; אסור לפתוח עד המדידה הסופית	מונע overfit סמוי דרך hyperparameter tuning	אין

שילוב D1-D4 : בטוח לחלוטין. discipline בלבד.

6§ · קבוצה E — Augmentation (קל, על מיעוטים בלבד)

הסיכום: רק על מחלקות מיעוט (hate , pornographic , violence), בקצב פי 2 maximum, ורק 3 טכניקות EDA.

#	טכניקה	מה היא עושה	איך היא עוזרת	סיכון
E1	EDA — Random Insertion	הכנס מילה אקראית (מה-vocab של train) במיקום אקראי	הוספת perturbations קלים שהמודל צריך להיות invariant אליהם	באנגלית — synonyms טובים יותר; בעברית — שימוש ב-vocab של train הוא הבטוח ביותר
E2	EDA — Random Swap	החלפת שתי מילים אקראיות במיקומם	בודק order-invariance של signals bag-of-features	החלפה מרובה הורסת דקדוק עברי
E3	EDA — Random Deletion	מחיקת כל מילה בהסתברות p (לדוגמה 0.1)	הכשרה ל-robustness לחוסר מילים	מחיקה מרובה (<20%) הורסת את ה-label signal
E4	EDA — Synonym Replacement	החלפת מילה לא-stopword ב- synonym	באנגלית — ה-EDA החזק ביותר; בעברית — WordNet-Hebrew דל	לדלג בעברית — סיכון של mis-augmentation גובר על תועלת
E5	Augment רק מחלקות מיעוט	augment פי 2 רק את ה-examples של violence/pornographic/hate	מטפל ב-imbalance מבלי להכפיל זמן אימון	אין — היפך הסיכון
E6	Augment רק על train split	אסור על validation או test	evaluation הוגן	אין

הגדרה: "פי 2" משמע — אם המקור הוא 100 דוגמאות של violence, אז train יקבל 200 (המקור + augmented 100 variants).

7§ · קבוצה F — נדחה למפגשים 6–8

לרשימה (לא לבצוע במפגש 5):

#	טכניקה	סיבת דחייה
F1	Back-translation (עברית → אנגלית → עברית)	preprocessing כבד ; עבודה למפגש 6
F2	LLM paraphrase augmentation (Claude/GPT-4o)	API cost ; דורש human spot-check ; מפגש 6
F3	Synthetic conversational data	האסטרטגיה הראשית של bullying_data_he.md ; מפורש למפגש 6
F4	DAPT (continue MLM על עברית פוגענית)	דורש corpus לא-מתויג שאין לנו במכלל
F5	Confident Learning (Northcutt 2021)	שימושי אם F1 נכשל ; 30 one-time דק'
F6	Mixup / Manifold Mixup	קשה לדבג ל-BERT ; דחייה ל-ablation אם צריך
F7	Curriculum learning	סדר easy→hard ; שיפור שולי
F8	Adversarial filtering	זריקת examples טריוויאליים ; שיפור שולי

§8 · ניתוח בטיחות שילוב — האם הטכניקות יחד יכולות לפגוע?

סיכון #1 — Over-correction של class imbalance (C1 + C2 + C3 בשילוב)

אם נשתמש בשלושת המנגנונים יחד (class-weighted CE + Focal Loss + class-balanced sampler), המודל יוכל לעבור מ-overrepresentation של non_offensive ל-overprediction של מחלקות מיעוט ב-inference. תוצאה: precision נמוך על המחלקות הנדירות → אזעקות שווא נוספות.

מיגון (במסלול המומלץ): - שימוש ב-C2 בלבד עם משקלים מובנים (זהו mechanism אחד, לא שניים) - **דילוג על C3** במפגש 5 - אם per-class recall של `violence` אחרי הריצה הראשונה $> 0.5 \rightarrow$ רק אז הפעלת C3 כניסוי נוסף

סיכון #2 — Compounding softening (C2 + C4 עם ϵ גבוה)

Focal Loss כבר ממתן על gradient smoothing. Label smoothing על confident-correct predictions גם מרכז targets גלובלית. עם ϵ גבוה ($\epsilon \leq 0.1$), ה-confidence של הרשת מרוסק כפול — calibration נראה טוב אך הסיגנל הדיסקרימינטיבי נחלש.

מיגון: - **label smoothing $\epsilon=0.05$** (לא 0.1) כשמשלבים עם Focal Loss - מסמך הארכיטקטורה הציע $\epsilon=0.1$; אנחנו מורידים ל-0.05 לסביבה ה-loss-משולב

סיכון #3 — Augmentation distribution shift (E1-E3 מוגזם)

אם נעשה augment למיעוטים פי 5 בלי לטפל ברוב, התפיסה של המודל של ההתפלגות המשותפת תהיה מוטעית. הוא יחשוב שהעולם הוא 50% מיעוט-מחלקה כשבפועל זה 5%. ההתפלגות של ה-output תהיה miscalibrated → סף ה-triage יצטרך re-tuning.

מיגון: - הגבלת augmentation למיעוטים ל-**פי 2** מהמקורי (כפי שנמצא בהמלצה) של re-fit calibrator (`training/calibrate.py`) על validation split שלא-augmented — כך ה-calibration משקף את ההתפלגות האמיתית

סיכון #4 — Lossy preprocessing (A6 מוגזם)

אם נמחק (במקום להחליף) URLs/mentions, ה-context הרלוונטי לתווית הולך לאיבוד. "friend you're an idiot@"
מאבד את ה-context החברתי (banter ידידותי vs. attack).

מיגון (במסלול המומלץ): - A6 מחליף ב- [URL] / [MENTION] placeholder tokens — שומר את האות הסטרוקטורלי

זוגות בטוחים מוכחים (משולבים בפרודקשן ב-Google/Meta/etc).

- $A1+A2+A3+A4+A5+A7$ (החבילה הניקוי — אדיטיבי, ללא סיכון)
- $B1+B2+B3$ (החבילה היעילות — אף אחד לא משנה את התנהגות המודל)
- $D1+D2+D3+D4$ (החבילה ה-discipline — אבן יסוד של evaluation הוגן)
- $C2$ (Focal עם משקלים מובנים) + $C4$ (label smoothing $\epsilon=0.05$)
- $E1+E2+E3$ capped at $2\times$ on minorities only

9§ Configuration & הרחבה עתידית

הצינור יהיה parameterized — כל בחירה היא knob:

```
from dataclasses import dataclass

@dataclass
class DataPrepConfig:
    # A. Cleaning
    dedup_jaccard_threshold: float = 0.85
    drop_min_tokens: int = 3
    drop_max_tokens: int = 200
    strip_nikud: bool = True
    url_replacement: str = "[URL]"          # set "" to delete
    mention_replacement: str = "[MENTION]"

    # B. Sequencing
    max_length: int = 96                    # set from p99.5 of training set

    # C. Class balance
    use_focal_loss: bool = True
    focal_gamma: float = 2.0
    use_class_weights_in_focal: bool = True
    use_balanced_sampler: bool = False      # turn ON only if recall_violence < 0.5
```



```

label_smoothing_epsilon: float = 0.05

# D. Splits
test_size: float = 0.10
val_size: float = 0.10
seed: int = 42
holdout_ocr_validation: bool = True # 1040 sentences for stylistic eval

# E. Augmentation
augment_minorities: bool = True
minority_augment_factor: int = 2 # max 5; >2 risks distribution shift
eda_techniques: tuple = ("random_insert", "random_swap", "random_delete")
eda_synonym_replacement: bool = False # E4 – keep OFF for Hebrew

```

מסלול ההרחבה לצורך best score

מפגש	מה להוסיף	למה
מפגש 5	הסטאק הנוכחי; שער ב- $F1 \geq 0.78$	נעילת ה-baseline
מפגש 6	Synthetic conversational data (F3); + revisit augmentation rate; + + Confident Learning אם $F1 < 0.80$	הוספת ממד שיחתי
מפגש 7	DAPT (F4) + corpus עברי-פוגעני מצטבר	דחיפה דומיין ל-1-2 pp אחרונים
מפגש 8	+ Final hyperparameter ablation; + דיווח כל הקומבינציות בתזה	ראייה empirically defendable

הכל ניתן להחלפה דרך הקובץ `data_prep_config.yaml` — אין צורך לשנות קוד.

§10 · אינטגרציה עם מסמך הארכיטקטורה

מסמך §9 [dictabert_classifier_architecture.md](#) מגדיר את ה-**data contract** — מה הקוד של ה-data prep חייב להפיק. המסמך הנוכחי מסביר למה המבנה הוא כזה ואיך להגיע אליו.

הטבלה ההצלבה:

הטכניקה הספציפית	המסמך הנוכחי מנמק	§9 בארכיטקטורה דורש
—	פורמט סטנדרטי לסיווג; HF Trainer קורא ישירות	JSONL {"text": str, "label": str}
C1 (משולב לתוך C2 כ- (alpha	תיקון imbalance ב-loss	class_weights.json
B1	smart from p99.5	max_length=128 baseline
D3	robustness eval	holdout style-1040
A1+A2+D2	cross-split discipline	no-leakage validator
A3+A4+A5	Hebrew normalization	NFKC + diacritic-strip
resolved G-02 in) (review.md	label vocabulary alignment	canonical non_offensive

§11 · סיכום למפגש 5

המסלול המאושר: 1. ☒ A1+A2+A3+A4+A5+A6+A7 (ניקוי + נורמליזציה מלא) 2. ☒ B1 (max_length=96) מ-B1 (dynamic padding) + B3 (Arrow cache) 3. ☒ C2 + (p99.5 Focal Loss $\gamma=2$) עם משקלי מחלקות) C4 (label + ☒ D1+D2+D3+D4 (full discipline) 4. ☒ E1+E2+E3 $\epsilon=0.05$ smoothing רק על מחלקות מיעוט פי 2

הימנעות: - ☒ C3 (balanced sampler) — שמור ל-fallback אם recall נמוך - ☒ C1 בנפרד — subsumed by C2 - ☒ E4 (synonym replacement) — חלש בעברית - ☒ F1-F8 — נדחים למפגשים 6-8

אבן השומר של המסלול הזה: $F1 \geq 0.78$ על SinaLab test split. אם נכשלים — נסיגה ל-mitigations: הפעלת C3, הגדלת γ focal, הוספת F5 (Confident Learning).