Shomer.AI — דיאגרמות ארכיטקטורה

מסמך: דיאגרמות עבור Architecture B (טקסט + Context Agent + Chat-OCR יחיד) **מקורות:** `plan-docs/decisions/architecture.decision.md` **סטטוס:** טיוטה למפגש 4 · 2026-05-31 **שימוש:** המסמך משובץ ב- `PRD.md` בסעיף הארכיטקטורה. ניתן גם לעיון עצמאי לצורך הגנת הארכיטקטורה.

למה שלוש דיאגרמות?

כל דיאגרמה עונה על שאלה אחרת — לא כל מי שיקרא צריך את כולן:

דיאגרמה	מה היא עונה	קהל מטרה
1 — C4 Container	"מה הרכיבים ואיפה הם רצים?"	ארכיטקטים, DevOps, ד"ר סגל במפגש 4
2 — Data Flow	"מה הזרימה הלוגית של הנתונים?"	מפתחים — וודאות שיש pipeline אחד ולא שניים
3 — Sequence (מקרה גבול)	"איך זה רץ בפועל בזמן אמת?"	מודיע על ה-RQ; מראה איפה ה-FP-reduction קורה

דיאגרמה 1 — תצוגת מערכת ברמת C4 Container

מציגה את כל המכלים (containers) של המערכת, את גבולות האמון (trust boundaries), ואת תזרים המידע הראשי בין הילד, השרת הביתי, השירות החיצוני (LLM בתשלום), וההורה.

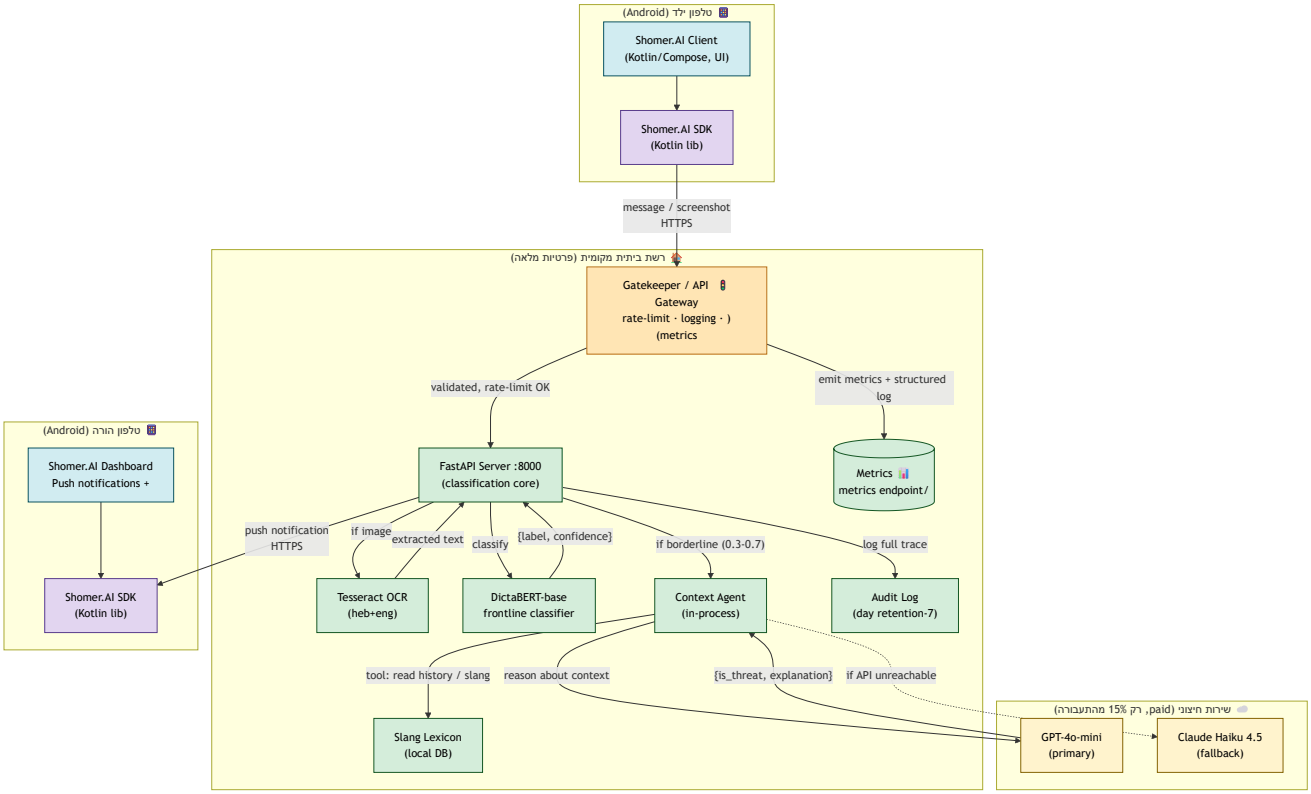

מקרא: - ירוק = רץ מקומית (פרטיות מלאה, אפס עלות שולית) - כחול = לקוח (Android, צד הילד וצד ההורה) - סגול = SDK — ספרייה משותפת ב-Kotlin שיושבת **בתוך** כל קליינט; עוטפת את חוזה ה-API - כתום = Gatekeeper / API Gateway — שכבת Edge של ה-FastAPI; שולטת בעומסים ומספקת observability - צהוב = שירות חיצוני בתשלום (פעיל רק על 15% מקרי גבול)

נקודות מפתח: 1. כל הנתונים הרגישים (תוכן השיחות, תמונות) **נשארים ברשת הביתית**. לשירות החיצוני נשלח רק קונטקסט מצומצם (הודעה + עד 5 תורים קודמים, ללא PII). 2. ה-LLM החיצוני **לא חסום-פעולה** — אם נופל, חוזרים על סיווג החזית עם דגל "needs human review". 3. כל החלטה של ה-Context Agent מתועדת ב-Audit Log עם reasoning trace מלא (חובה לניתוח per-slice במפגש 8). 4. **SDK** (סגול) הוא חוזה ה-API היחיד שכל קליינט (אנדרואיד-ילד, אנדרואיד-הורה, web עתידי, 3rd-party integrations) ניגש דרכו. מונע שכפול קוד HTTP בין הקליינטים. 5. **Gatekeeper / API Gateway** (כתום) הוא שכבת Edge: כל בקשה עוברת דרכה לרייט-לימיט, validation, ולוגינג מובנה לפני שמגיעה לסיווג. מימוש + `structlog` + `slowapi`) FastAPI middleware = MVP `prometheus-fastapi-instrumentator`). מטרתו תפעולית — שליטה בעומסים + observability — ולא חלק מהסיווג עצמו.

דיאגרמה 2 — Data Flow: שני מסלולי הקלט מתאחדים

מראה איך הודעת טקסט וצילום מסך חולקים את אותו pipeline מהמסווג הקדמי ואילך. **זוהי בדיוק ההצדקה לדחיית Architecture A** — אין צורך ב-Vision LLM כי הטקסט שבתוך התמונות חולץ דרך OCR ונכנס לאותו צינור.

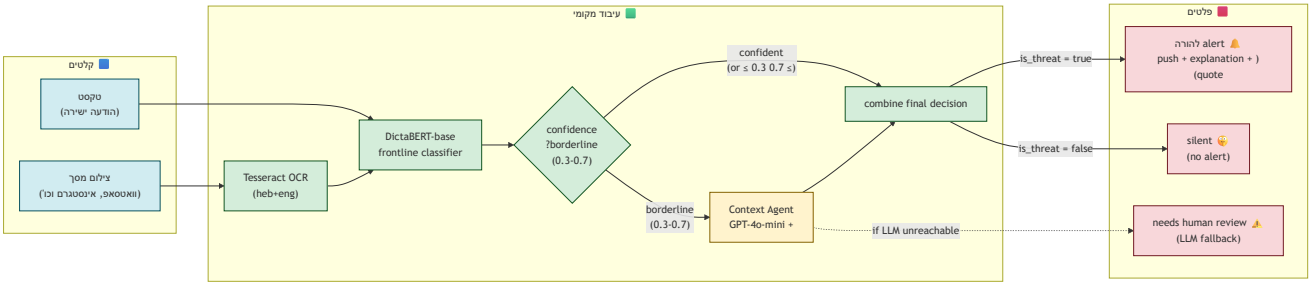

המסר העיקרי: OCR קורא טקסט מתוך תמונות → הטקסט נכנס לאותו pipeline. אין שני pipelines נפרדים. החיסכון הזה הוא ההצדקה ההנדסית לוויתור על Vision LLM (Architecture A).

שלוש האפשרויות הסופיות: - **Alert** — התראת push להורה עם הסבר וציטוט (לא קופסה שחורה) - **Silent** — הסיווג קבע שהמקרה תמים, אין הפרעה להורה (Alert Fatigue מינימלי) - **Manual review** — מסומן רק כשה-LLM החיצוני אינו זמין (graceful degradation)

דיאגרמה 3 — Sequence: זרימת מקרה גבול עם reasoning של Context Agent

מציגה את הסדר הכרונולוגי המלא — מהילד שולח הודעה ועד להתראה (או לא) אצל ההורה — במקרה גבול שדורש את ה-Context Agent. דיאגרמה זו היא הליבה של ה-RQ: היא מראה **איפה ולמה** ה-FP-reduction קורה.

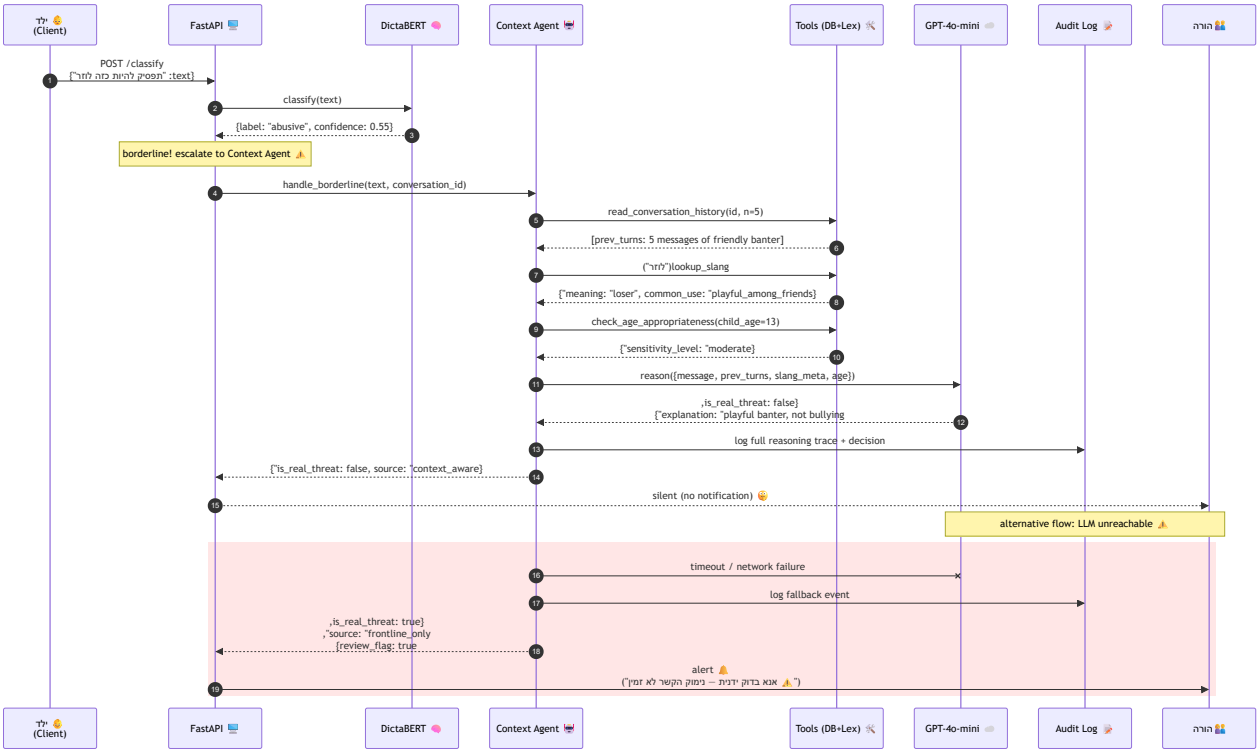

מה הדיאגרמה מראה (נקודות לציון בהגנה):

1. **השלבים 1–3 (סיווג ראשוני):** רץ במאות מיליאניות — DictaBERT מקומי, ללא קריאות חיצוניות.

2. **השלב 4 (החלטת הסלמה):** רק כשה-confidence ב-(0.3–0.7) borderline zone. זה ה-15% מהתעבורה שמגיע ל-Context Agent ומגלם את עיקר ה-cost.

3. **השלבים 5–10 (ה-Context Agent):** הסוכן קורא היסטוריה + מילון סלנג + פרופיל גיל **לפני** הקריאה ל-LLM. הכלים חוסכים טוקנים ע״י הזרמת רק המידע הרלוונטי.

4. **השלב 11 (reasoning):** ה-LLM החיצוני (GPT-4o-mini) מקבל קונטקסט תמציתי ומחזיר החלטה + הסבר. **זה המנגנון שעונה על ה-RQ** — סיווג ההודעה ה״גבולית״ משתפר ע״י reasoning על ההקשר.

5. **השלב 14 (תוצאה):** במקרה הזה ה-Context Agent קבע שהמסר תמים (סלנג ידידותי בהקשר של שיחה צוחקת) → **אין התראה** → **הפחתת FP**.

6. **המסלול האדום (fallback):** אם ה-LLM אינו זמין, המערכת לא חוסמת את ההתראה — שולחת אותה עם דגל ״needs human review״. עיקרון: **לעולם לא לאבד התראה בשקט במערכת בטיחות ילדים**.

איך הדיאגרמות מעידות על ה-RQ

שאלת המחקר: *״עד כמה הוספת הקשר שיחתי לסיווג בריונות בעברית מפחיתה את שיעור ה-false positives לעומת סיווג מבודד — מבלי לפגוע ב-recall?״*

הניסוי המוטמע בארכיטקטורה: - **תנאי control (context-blind):** המסווג בלבד מחליט. בדיאגרמה 3, זה השלבים 1–3 בלבד; ההחלטה תהיה לפי is_threat = true״ → `confidence ≥ 0.5` ״ → **התראת FP**. - **תנאי treatment (context-aware):** המסווג + Context Agent. בדיאגרמה 3, זה הזרימה המלאה; ההחלטה לאחר reasoning → is_real_threat = false״״ → **התראה נמנעה**. - **המדידה:** הפרש ה-FPR בין שני התנאים על gold set מתויג ידנית (מפגש 8).

הארכיטקטורה לא רק תומכת ב-RQ — היא **מממשת את הניסוי כפיצ׳ר מובנה** של המוצר.