

Shomer.AI — מאמרי דגל וקשר לשאלת המחקר

סטטוס: עודכן 2026-05-27 — מותאם לשאלת המחקר **המחודשת** (בריונות תלוית-הקשר + הפחתת false positives).
הגרסה הקודמת (2026-05-24) עיגנה ציר רב-מודאלי שירד עתה לסטטוס **משני** — ראו plan-/.
docs/decisions/research-framing.decision.md (החלטה D-Reframe-2026-05-27). **מקור היסטורי:**
plan-docs/related_work.he.md/. **ביבליוגרפיה מאומתת:** references.bib.

שאלת המחקר החדשה יושבת בצומת: **זיהוי בריונות בעברית (שפה זלת-משאבים) + שימוש בהקשר שיחתי כדי להפחית התרעות-שווא + נתונים סינתטיים-שיחתיים**. אף מאמר יחיד אינו מכסה את הצומת הזה — ובמיוחד אין מאמר עברי על בריונות תלוית-הקשר. זה בדיוק הפער שהפרויקט ממלא. להצהיר על כך במפורש ב-Related Work.

IL זמינות בעברית — קודם כול, התשובה הישירה

את ביקשת דגש על עברית. האמת ההוגנת, שכדאי להציג לוועדה כהצדקה לפער:

מה קיים בעברית	מה זה נותן	מה חסר (= התרומה)
SinaLab / Hamad et al. (2023) — קורפוס פוגעני עברי	סכמת תוויות + baseline טקסטואלי	הודעות בודדות, לא שיחות — אין בו הקשר שיחתי כלל
DictaLM 2.0 / DictaBERT / AlephBERT	מודלים עבריים לבסיס ה-fine-tune	מודלים, לא דאטה; אינם עוסקים בבריונות או בהקשר

מסקנה: אין דאטהסט עברי של שיחות בריונות, ואין מאמר עברי על הקשר שיחתי. כל מאמרי ההקשר (Pavlopoulos, Sap, SynBullying) הם באנגלית. זה ההצדקה: הפרויקט מעביר תובנה מוכחת באנגלית אל עברית, שבה היא טרם נבדקה — וזו תרומה לגיטימית, לא חזרה.

עוגן 1 (עברי) — דאטהסט ומסגרת המשימה

Hamad, N., Jarrar, M., Khalilia, M., & Nashif, N. (2023). "Offensive Hebrew Corpus and Detection using BERT." AICCSA 2023. arXiv:2309.02724. [hamad2023offensive_hebrew]

- דאטהסט:** <https://huggingface.co/datasets/SinaLab/Offensive-Hebrew> · קוד:
- <https://arxiv.org/abs/2309.02724> · מאמר: <https://github.com/SinaLab/OffensiveHebrew>
- מה מספק:** 15,881 ציורים, תיוג רב-תוויתי בחמש מחלקות — abusive | hate | violence | pornographic | none-offensive. רק ~1,200 פוגעניים.
- קשר לשאלה החדשה:** מגדיר את סכמת התוויות ואת ה-baseline הטקסטואלי המבודד; הוא בדיוק התנאי ה-context-blind שמולו השאלה משווה. החיסרון שלו (ציורים בודדים) הוא המנוף של התזה.

-  **אומת (2026-05-27):** המחבר הראשי הוא **Hamad** (לא Jarrar). שם המחלקה החמישית: none-offensive.

עוגן 2 (הקשר) — האם הקשר חשוב? העוגן האינטלקטואלי החדש

Pavlopoulos, J., Sorensen, J., Dixon, L., Thain, N., & Androutsopoulos, I. (2020). "Toxicity Detection: Does Context Really Matter?" ACL 2020. [pavlopoulos2020context] 4305–4296. עמ'

- **מאמר:** <https://aclanthology.org/2020.acl-main.396/>
- **מה מספק:** המאמר הקאנוני על הקשר. ממצא מפתח: הקשר יכול גם להגביר וגם להחליש רעילות נתפסת — אך שרשרת-הקשר נאיבי נותן שיפור **שולי**. כלומר איך לנצל הקשר ביעילות הוא בעיה פתוחה.
- **קשר לשאלה החדשה:** מעגן את כל ציר ה-context-aware מול context-blind. הממצא ה"שולי" שלהם הוא בדיוק מה שהשאלה שלך בודקת מחדש — הפעם בעברית, עם מודל מודרני, ובמיקוד על FPR ולא רק accuracy.
- **תוסף עדכני:** "Humans Need Context, What about Machines?" (LREC-COLING 2024, [humans2024context] <https://aclanthology.org/2024.lrec-main.740/>) — מראה שהתחום חי ב-2024 ומציע ארכיטקטורות מעבר ל-concatenation.

עוגן 3 (התרעות-שווא) — מחיר הסיווג חסר-ההקשר

Sap, M., Card, D., Gabriel, S., Choi, Y., & Smith, N. A. (2019). "The Risk of Racial Bias in Hate Speech Detection." ACL 2019. [sap2019risk] 1678–1668. עמ'

- **מאמר:** <https://aclanthology.org/P19-1163/>
- **מה מספק:** הוכחה ש-classifiers חסרי-הקשר מתייגים בטעות עד ~50% מטקסט לא-פוגעני (בניב מסוים) כפוגעני. זו בדיוק כשל ה-false-positive שהשאלה שלך מכוונת אליו — "הנחות על בסיס המידע כמו שהוא".
- **קשר לשאלה החדשה:** מעגן את ציר ה-FP. משלים: Davidson et al. (2019), [davidson2019racial], arXiv: 1905.12516.

עוגן 4 (מתודולוגיית נתונים) — סינתזת שיחות

מאחר שאין דאטה שיחתי עברי, הנתונים **חייבים להיווצר**. שלושת אלה מעגנים את השיטה:

- **התקדים הקרוב** — SynBullying (Kazemi et al., 2025). [kazemi2025synbullying] arXiv: 2511.11599
- **ביותר:** דאטהסט שיחתי-סינתטי לבדיונות, שנוצר במספר LLMs. תבנית-שיטה ישירה.
- **prompting** — ToxiGen (Hartvigsen et al., ACL 2022). [hartvigsen2022toxigen] מבוסס-דוגמאות + classifier-in-the-loop; fine-tune על הסינתטי **שיפר ביצועים על טקסט אנושי**. הביסוס לכך שסינתטי עובד.
- **"Synthetic vs. Gold"** (Kazemi et al., 2025). [kazemi2025synthetic] arXiv: 2502.15860 — עד כמה לסמוך על תוויות/דאטה סינתטיים. מבסס את עקרון **train-on-synthetic / evaluate-on-real**.

עוגן 5 (מתודולוגיה) — QLoRA (נשמר מהגרסה הקודמת)

Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). "QLoRA." NeurIPS 2023. arXiv:2305.14314. [dettmers2023qlora]

- מצדיק את ה-fine-tune יעיל-הפרמטרים על מודל עברי (Qwen2.5-7B / DictaLM 2.0) → Ollama → GGUF מקומי. ☒ אומת.

ציר משני (לא ראשי) — מודרציה רב-מודאלית של תמונות

ציר ה-routing של OCR-מול-VLM ירד מסטטוס "עמוד שדרה" למסלול משני/אופציונלי עם המעבר לשאלה השיחתית. נשמר כי תמונות מופיעות בשיחות צ'אט, וההנדסה כבר בנויה (Phase 2/4). אנלוגים תומכים: LLaVA (Liu et al., 2023, [liu2023llava]) ל-VisionBackend; Tesseract (Smith, 2007, [smith2007tesseract]) ל-OCR. ☒ שניהם אומתו. ההכרעה הסופית על מקומו של הציר הזה — במפגש 4 (ארכיטקטורה).

מיפוי מאמר → שאלת מחקר (מחודש)

מאמר	שפה	תומך ב-
SinaLab Offensive-Hebrew	IL עברית	סכמה + baseline מבודד (context-blind)
Pavlopoulos 2020	אנגלית	ציר ההקשר (RQ ראשית)
Sap 2019 / Davidson 2019	אנגלית	ציר ה-false-positives (RQ ראשית)
SynBullying / ToxiGen / Synthetic-vs-Gold	אנגלית	מתודולוגיית הנתונים הסינתטיים
QLoRA	—	מתודולוגיית fine-tune
LLaVA / Tesseract	—	ציר רב-מודאלי (משני)

פעולות פתוחות

- לאמת את רשימת המחברים של [humans2024context] (LREC-COLING 2024) מול ACL Anthology לפני ההגשה הסופית.
- לעדכן את קטלוג ה-8 (../plan-docs/research_questions.md) RQs כך ש-RQ הראשית תהיה ההקשר/FP ולא RQ3 הרב-מודאלי — לתאם במפגש 4.