

## Shomer.AI — סדר יום למפגש 4

מועד: יום א' · 31/05/2026 מנחה: ד"ר יורם סגל מציגה: אלונה משך מתוכנן: 60–90 דקות מטרת המפגש: הקפאת הארכיטקטורה + אישור ה-PRD → שחרור לבנייה במפגש 5

### תוצרים שאני מביאה למפגש

| תוצר                                            | קישור                                              | סטטוס  |
|-------------------------------------------------|----------------------------------------------------|--------|
| PRD מלא (15 סעיפים, עם דיאגרמות)                | <a href="#">PRD.md</a>                             | מוכן ✓ |
| מסמך החלטות ארכיטקטוניות                        | <a href="#">architecture.decision.md</a>           | מוכן ✓ |
| דיאגרמות ארכיטקטורה (C4 + Data Flow + Sequence) | <a href="#">architecture_diagrams.md</a>           | מוכן ✓ |
| Reframe reconciliation (סגירת לולאה עם M3)      | <a href="#">reframe-reconciliation.decision.md</a> | מוכן ✓ |
| שאלות פתוחות עם ברירות מחדל                     | <a href="#">open_questions.md</a>                  | מוכן ✓ |
| תכנית עסקית (מהמפגש הקודם, בלי שינוי)           | <a href="#">business_plan.md</a>                   | קיים ✓ |

### חלק 1 · עדכון סטטוס מאז מפגש 3 (10 דקות)

#### מה בוצע בין M3 ל-M4 (3 ימים)

- שאלת מחקר מוקדה מחדש (27/05) — ראו D-Reframe-2026-05-27 - מ: RQ3 multimodal image routing - ל: הוספת הקשר שיחתי להפחתת FP בעברית (RQ ראשי + RQ1 כיסוד) - למה: ההכרעה הראשית של הקורס דורשת תרומה אקדמית ברורה ומדידה — ציר ההקשר נקי יותר וניתן למדידה ישירה
4. — (30/05) Phase 0 deliberation החלטות ארכיטקטוניות + OCR 1 - וריאנט ארכיטקטורה: B (טקסט + Chat-OCR, לא vision LLM) - מודל בסיס: DictaBERT-base (Hebrew encoder) - צורת המערכת: Context Agent יחיד (לא 3 סוכנים) - LLM של ה-OCR - Haiku 4.5 fallback - GPT-4o-mini primary Context Agent: engine: Tesseract (heb+eng)
3. PRD מלא נכתב — 15 סעיפים, כולל 3 דיאגרמות mermaid, סיכונים, KPIs, NFRs, ו-roadmap למפגשים 5–10
7. שאלות מוצר נדחו (מתועדות עם ברירות מחדל) — להכרעה בסשנים ייעודיים לפני מפגשים 5/7

#### מה לא נעשה (במכוון)

- MoSCoW סופי של פיצ'רים (נדחה למפגש ייעודי)

- בנייה / קוד (חוזה לפני בנייה, 9 slide per)

## חלק 2 · הצגת הארכיטקטורה (15–20 דקות)

הצגה לפי דיאגרמה 1 ב-PRD סעיף 7.2 (C4 Container) : - שני קצוות לקוח (טלפון ילד + טלפון הורה) - שרת FastAPI מקומי ברשת הביתית - ה-pipeline המקומי : Context Agent → DictaBERT → OCR - קריאה חיצונית רק על 15% מהמקרים (gray-zone) - מנגנון fallback אם ה-LLM החיצוני נופל

**מסר עיקרי:** הארכיטקטורה היא הניסוי. אפשר להפעיל/לכבות את ה-Context Agent ולקבל ניסוי A/B נקי לסיווג context-blind מול context-aware.

**להזכיר:** דיאגרמה 3 (Sequence) מראה את ה-FP-rescue בפועל — הקיים של "תפסיק להיות כזה לוזר" שמסומן (0.55) borderline, עולה ל-Context Agent, הסוכן קורא היסטוריה ומילון סלנג, מסיק שזו הקנטה ידידותית, ולא נשלחת התראה.

## חלק 3 · הגנת ההחלטות הארכיטקטוניות (15–20 דקות)

לכל הכרעה — מה נבחר, למה, ומה הדחיתי. ראו `architecture.decision.md` להגנה מלאה.

### למה Architecture B ולא A (multimodal)?

- vision LLM חלש בעברית → מערפל את ה-RQ הניסויי
- מפוצץ את התקציב (~\$0.008/interaction + 5% image traffic)
- הקיים המסחרי הראשי של "shomer" הוא טקסט + צילומי מסך, לא תמונות עירום
- Architecture A מתועדת כ-future work, לא נמחקה

### למה DictaBERT ולא Qwen / DictaLM?

- DictaBERT-base מנצח באיכות-לעלות לעברית במחלקת ה-lightweight
- אין צורך בגרעיה (ה-Context Agent מספק reasoning); encoder מספיק
- רץ על RTX 5080 → CPU פנוי לאימון

### למה Context Agent יחיד ולא 3?

- Alert ו-Triage ניתנים להחלפה בקוד דטרמיניסטי בלי לפגוע באיכות
- ~\$2,500/חודש חיסכון בעולם המסחרי
- Context Agent יחיד = ה-mechanism שעונה ישירות על ה-RQ (מנגנון FP-reduction מבודד)

## למה GPT-4o-mini ולא Haiku 4.5 ?

- אסטרטגיית **test-cheap-first** — שני המודלים פיזית פנויים לבחירה
- מודדים F1 על gold set במפגש 8 → אם mini עומד ביעד, חוסכים \$2,500/חודש בעולם המסחרי
- אם לא — Haiku בא להציל כ-fallback מתועד

## למה Tesseract ולא PaddleOCR / MLKit ?

- חינם, מקומי (שומר פרטיות)
- מספיק טוב לשלב הזה ; קל להחליף אם מפגש 8 יראה שזה bottleneck
- MLKit on-device מתועד כשדרוג עתידי (= פרטיות עוד יותר חזקה)

---

## חלק 4 · בקשת אישור (10 דקות)

---

### שואלת אישור מפורש על:

1. ☒ הארכיטקטורה שנעלה (סעיף 7 ב-PRD)
2. ☒ ה-RQ והיעדים המדידים (סעיף 6 ב-PRD)
3. ☒ הרכיבים והגדרותיהם (סעיף 8 ב-PRD)
4. ☒ ה-NFRs וה-KPIs (סעיפים 9, 10 ב-PRD)
5. ☒ ה-Out-of-scope המכוון (סעיף 11 ב-PRD)
6. ☒ RQ + ל-POC (סעיף 4 + reframe-reconciliation)

### שאלות שאני שואלת את ד"ר סגל:

1. האם הווייתור על Vision LLM (Architecture A) מקובל בהתחשב במיקוד ב-RQ? (אם לא — צריך להחזיר vision branch ולתכנן מפגש 7 מחדש ; זמן יקר)
  2. האם דרישת "3 סוכנים" מההצעה המקורית חייבת לחזור, או שסוכן יחיד מקיים את ה-agent mandate של הקורס? (אם חייב 3 — נצטרך לבנות Triage/Alert גם אם הם דטרמיניסטיים, רק לעמוד בדרישה)
  3. האם יש מאמרים נוספים שכדאי לעגן בהם את החלטת הארכיטקטורה? (אנקור ראשי : Pavlopoulos 2020. מאמרים נוספים שהמנחה יציע נוסף ל-literature\_flagship)
  4. האם 7 השאלות הפתוחות (open\_questions.md) הוגנות לדחייה לסשנים ייעודיים? (ל עודא שלא נופלים על שאלת מוצר קריטית במהלך הבנייה)
-

חלק 5 · Roadmap למפגש 5 ואילך (5 דקות)

| מפגש | תוצר ראשי                                              | תלוי ב               |
|------|--------------------------------------------------------|----------------------|
| 5    | SinaLab; $F1 \geq 0.78$ על DictaBERT-base fine-tuned   | אישור היום           |
| 6    | סינתזת שיחות עבריות מתויגות; פיילוט Context Agent      | סגירת Open Q 1, 4, 6 |
| 7    | Context Agent מלא + 3 tools + נתיב התראה               | סגירת Open Q 3, 5, 7 |
| 8    | Gold set אמיתי + הערכה context-blind מול context-aware | מפגש 7               |
| 9    | סרטון Nano-Banana, שיר SUNO, דמו מלוטש                 | מפגש 8               |
| 10   | הגנת תזה + הגשה סופית                                  | מפגש 9               |

מה אני עושה אחרי המפגש

- אם מאושר → `v0.4 Design Frozen` tag ב-push ב-GitHub כל המסמכים
- אם יש שינויים → תיקון `PRD/architecture.decision.md` ביום, push עם תג `v0.4.1`
- תוך 3–5 ימים: ששן ייעודי לשאלות הפתוחות 1, 4, 6 (חוסמות את מפגש 5)
- שבוע אחרי: מתחילים מפגש 5 (fine-tune DictaBERT)

תוצרים מקומיים שיוגשו (קישורים)

| תוצר                      | נתיב מקומי                                                             | סטטוס PDF          |
|---------------------------|------------------------------------------------------------------------|--------------------|
| PRD מלא                   | <a href="#">docs/PRD.md</a>                                            | ייוצר אחרי כתיבה ⌚ |
| מסמך החלטות ארכיטקטוניות  | <a href="#">plan-docs/decisions/architecture.decision.md</a>           | אנגלית, נשאר MD    |
| Reframe reconciliation    | <a href="#">plan-docs/decisions/reframe-reconciliation.decision.md</a> | אנגלית, נשאר MD    |
| דיאגרמות ארכיטקטורה       | <a href="#">docs/architecture_diagrams.md</a>                          | ייוצר אחרי כתיבה ⌚ |
| שאלות פתוחות / Next Steps | <a href="#">docs/open_questions.md</a>                                 | ייוצר אחרי כתיבה ⌚ |
| סדר יום זה                | <a href="#">docs/meeting4_agenda.md</a>                                | ייוצר אחרי כתיבה ⌚ |