

Shomer.AI — דו"ח אימות מודול ה-OCR

תאריך: 2026-06-03 · עדכון לקראת מפגש 5 (04/06/2026) מנחה: ד"ר יורם סגל מצב: טיוטה למפגש 5 — תוצאות
אמפיריות מהשבוע

1. רקע

הארכיטקטורה שנעלה במפגש 4 ([architecture.decision.md](#)) כוללת (`heb+eng`) Tesseract OCR כגשר בין צילומי מסך של שיחות לבין המסווג בעברית (DictaBERT). לפני השקעה של ארבעה שבועות בפיתוח המסווג והסוכן, ביצענו אימות אמפירי של Tesseract על תוכן צ'אט עברי אמיתי.

שאלת המחקר של האימות: האם Tesseract מטפל באיכות מספקת בתוכן הצ'אט של ילדים ישראלים — כולל שגיאות כתיב, ערבוב עברית-אנגלית, וכתוב פונטי?

הסיכון אם לא בודקים: השקעת זמן בפיתוח על תשתית שלא קוראת עברית = בזבוז של 4+ שבועות.

2. מתודולוגיה

2.1 דאטהסט

- 1040 משפטים** ב-4 סגנונות (~260 לכל סגנון), שנוצרו ע"י 40 + **Gemini 2.5 Flash** (~1000) משפטי seed שנכתבו ידנית כעוגן.
- 50% מהמשפטים מכילים תוכן פוגעני** בהתאם לסכמת SinaLab — שימוש חוזר עתידי לאימון DictaBERT.
- כל משפט רונדר לתמונה PNG בסגנון בועת WhatsApp עברית (RTL, פונט David, רעש קל).
- ה-1040 כולל מגוון של תוכן ניטרלי, מתעלל (bullying), שנאה, אלימות, ותוכן מיני לא הולם.

2.2 ארבעת הסגנונות

סגנון	תיאור	דוגמה
A	עברית פורמלית נכונה	"היום למדנו על הגיאוגרפיה של ישראל בשיעור מולדת"
B	עברית ילדים, 10-15% שגיאות + סלנג	"אנחנו הלכנו לגן ציבורי ושחקנו כדורגל בשביל מלא זמן"
C	Code-switching עברית/אנגלית	"אני so done עם בית הספר היום literally לא יכולה"
D	כתיב פונטי לקוי (דובר ילידי)	"באלי לאחול פיזה אבל אין באית"

2.3 מדדים

1. CER (Character Error Rate) — מרחק Levenshtein ברמת התו, מנורמל
2. WER (Word Error Rate) — אותו דבר ברמת המילה
3. TF-IDF char-n-gram cosine — דמיון לקסיקלי-סמנטי (proxy לאיכות שמשפיע על המסווג הקדמי). הוחלף מ-DictaBERT (תכנון מקורי) ל-TF-IDF char-n-gram בגלל rate-limit ב-Hugging Face Hub. שני המדדים מצוטטים בספרות OCR כ-proxy תקני.

2.4 ספים שנקבעו מראש (pre-registered)

סגנון	סף CER מקסימלי
A, B, C	15%
D	25% (קייס קצה — דמוגרפיה משנית)

הספים תועדו ב- ocr-validation-plan.md-00 לפני הרצת הניסוי, למניעת HARKing (Hypothesizing After Results are Known).

3 · תוצאות

3.1 טבלת תוצאות לכל סגנון

סגנון	N	CER ממוצע	CER p90	WER ממוצע	Cosine ממוצע	Verdict
A — עברית ברורה	260	5.2%	15.4%	10.0%	0.910	✓ עבר (CER 5.2% ≤ 15%)
B — ילדים עם שגיאות	260	6.4%	18.4%	11.5%	0.880	✓ עבר (CER 6.4% ≤ 15%)
C — Code-switching	260	19.0%	43.4%	30.0%	0.735	✗ נכשל (CER 19.0% > 15%)
D — כתיב פונטי לקוי	260	7.4%	20.2%	12.2%	0.872	✓ עבר (CER 7.4% ≤ 25%)

3.2 השפעת ה-bidi markers (תובנה מתודולוגית)

Tesseract מכניס סימוני RTL/LTR (U+200E, U+200F, וכו') סביב נקודות מעבר עברית↔אנגלית ובסוף שורות. אלה לא טעויות זיהוי אמיתיות — אנו פותחים אותם לפני חישוב המדדים כדי לקבל מספר הוגן.

סגנון	CER גולמי	CER נקי	הפרש (נופח)
A	5.4%	5.2%	0.3%
B	7.0%	6.4%	0.7%
C	21.1%	19.0%	2.0%
D	7.9%	7.4%	0.5%

3.3 ניתוח לפי קטגוריות תוכן פוגעני (חדש — N=1040)

מעבר לסגנונות הלשוניים, ניתחנו את ה-OCR לפי קטגוריות התוכן (סכמת SinaLab):

קטגוריה	N	CER ממוצע	אחוז הצלחה	איכות גבוהה ($CER \leq 10\%$)	Cosine
none (ניטרלי (לא-פוגעני))	540	9.1%	82%	68%	0.864
abusive (מתעלל / בריונות)	200	11.3%	77%	60%	0.817
hate (שנאה / אפליה)	120	7.8%	82%	66%	0.858
violence (אלימות / איומים)	120	7.6%	84%	72%	0.861
pornographic (מיני לא הולם)	60	14.4%	73%	53%	0.781

הממצא: OCR מציג שיעורי הצלחה דומים (73-84%) בכל הקטגוריות — לא רואים פגיעה סלקטיבית בתוכן פוגעני. כלומר אם המסווג למטה ייתן תוצאות חלשות על תוכן פוגעני, זה לא בגלל OCR — זה מקור אחר (סלנג, פערי דאטה, וכו'). פורנוגרפי הוא הקטגוריה החלשה ביותר (73%) — סביר שזה בגלל ש-Gemini הוסט לניסוחים יותר עקיפים בגלל safety constraints.

3.4 גרפים (תוצרי T5 + T7)

הגרפים נשמרו ב- `/data/ocr_validation/charts`:

1. `cer_histogram_by_style.png_01` — התפלגות CER לכל סגנון (4 שכבות צבע)
2. `cosine_histogram_by_style.png_02` — התפלגות דמיון סמנטי לכל סגנון
3. `mean_cer_by_style_bar.png` — bar chart ראשי, עם קווי הסף שנקבעו מראש
4. `cer_vs_cosine_scatter.png_04` — פיזור CER מול cosine (מראה אם השגיאות הורסות משמעות)
5. `confusion_chart.png_05` — התווים שמבולבלים הכי הרבה ע"י Tesseract
6. `cer_histogram_by_category.png_06` — התפלגות CER לכל קטגוריית תוכן פוגעני
7. `success_rate_by_style_category.png_07` — אחוז הצלחה ב- $(Style \times Category)$
8. `overall_success_per_category.png_08` — אחוז הצלחה כללי לכל קטגוריית פוגעניות

4 · ממצאי מפתח

1. עברית טהורה (סגנונות A, B): מצוין. Tesseract עובד באיכות מסחרית. אין מקום לדאגה.
2. כתיב פונטי לקוי (סגנון D — האנלפביתי החדש): מפתיע לטובה. Tesseract לא מנסה לתקן שגיאות פונטיות — קורא בדיוק מה שכתוב.
3. Code-switching (סגנון C): החלש כצפוי. Tesseract מתבלבל במעבר עברית→אנגלית ומכניס סימוני RTL. הקטגוריה היחידה שכושלת בכל קטגוריות התוכן (54-63% הצלחה).
4. תוכן פוגעני לא פוגע ב-OCR (ממצא חדש N=1040): כל קטגוריות התוכן הפוגעני (hate 82% · abusive 77% · pornographic 73% · violence 84%) מציגות שיעורי הצלחה דומים לתוכן הניטרלי (82%). OCR יציב על פני קטגוריות תוכן — שגיאות מסווג עתידיות לא יהיו בגלל OCR סלקטיבי.
5. המדד הסמנטי (cosine): משלים את CER. גם כשיש שגיאות תווים, ה-embedding נשמר ברוב המקרים — כלומר המסווג בעברית עדיין יקבל החלטה נכונה מהפלט.

5 · מסקנה והמלצה

מסקנה: Tesseract עובר ב-3/4 סגנונות. מומלץ להמשיך איתו עם תיעוד מגבלה ספציפית; להעריך EasyOCR כ-fallback למפגש 8.

צעדים הבאים

- **אם Tesseract עובר:** ממשיכים ל-Phase 3 (fine-tune DictaBERT) ללא חשש OCR
- **אם נכשל:** EasyOCR מתועד כ-fallback ב-[architecture.decision.md](https://arxiv.org/abs/2007.01818). זמן החלפה: ~2 שעות בלבד (זהה API, השוואה מובחנת על אותו דאטהסט)
- **בלי קשר:** המלצה לשלב המשך — להוסיף מילון תיקוני סלנג + בדיקה נוספת על צילומי מסך אמיתיים מהשטח (במפגש 8)

למה הניסוי הזה היה חשוב

לולא הרצנו את האימות הזה, היינו עלולים לגלות רק במפגש 8 ש-OCR לא קורא עברית — אחרי שהשקענו שבועות בפיתוח DictaBERT והסוכן. כעת אנו יודעים את התשובה לפני שמתחילים לבנות. זו ההצדקה ל-3 ימי האימות.

6 · מקורות לאימות

- כל המספרים בדו"ח זה מבוססים על ([metrics_summary.csv](#)) ([data/ocr_validation/metrics.csv](#))
- אימות ויזואלי של כל הזוגות (תמונה ↔ OCR): [data/ocr_validation/verification.html](#)
- סקריפטים שהריצו את הניסוי: [scripts/ocr_validation/01_generate_sentences.py](#) ועד [summary_report.py_06](#)
- מסמך החלטה ארכיטקטוני: [ocr-engine-validation.decision.md](#) (ייתכן לאחר אישור הדו"ח הזה)