

Shomer.AI — מסמך דרישות מוצר (PRD)

מסמך: מסמך דרישות מוצר מלא להגשה במפגש 4 גרסה: 1.0 (טיוטה למפגש 4) · 2026-05-31 מנחה: ד"ר יורם סגל ·

קורס מומחי AI סטטוס: ממתין לאישור מנחה במפגש 4 מקורות: [research_question.md](#) ·

[bullying_data_he.md](#) · [architecture_diagrams.md](#) · [literature_flagship.md](#) ·

[business_plan.md](#) החלטות מעוגנות: [research-](#) [architecture.decision.md](#) ·

[open_questions.md](#) · [framing.decision.md](#)

1. תקציר מנהלים

Shomer.AI הוא שומר דיגיטלי שקט להורים: מערכת AI עברית-ראשון לזיהוי בריונות, איומים, תכנים מיניים ושיח מצוקה רגשית בתקשורת הדיגיטלית של ילדם — המבטיחה את הקשר השיחה ולא רק את ההודעה הבודדת.

ההבחנה המרכזית: כלי הקיימים בשוק שופטים כל הודעה במנותק, ולכן מציפים בהתראות שווא (Alert Fatigue) שמובילות לנטישת המוצר. Shomer.AI מבוסס על שכבת Context Agent המנמקת על שיחה מלאה לפני שליחת התראה — מנגנון שמטרתו מדידה ישירות בשאלת המחקר.

מה ייבנה במסגרת התזה (מפגשים 5–8): 1. מסווג טקסט עברי (DictaBERT-base) מאומן ב-fine-tune על SinaLab Offensive-Hebrew + נתונים סינתטיים של שיחות 2. צינור OCR (Tesseract) לחילוץ טקסט מצילומי מסך 3. סוכן הקשר (Context Agent, GPT-4o-mini) המפעיל reasoning על מקרי גבול 4. שרת FastAPI מקומי + אפליקציית Android להורה 5. Client SDK משותף (/server/sdk) — חוזה API קלאסי שגם אפליקציית האנדרואיד וגם משלבים עתידיים (web, 3rd-party) ימשכו דרכו. הופך את Shomer.AI ממוצר-קליינט יחיד למוצר עם API ניתן-לאינטגרציה. 6. מערך הערכה על gold set אמיתי עברי (~150 דוגמאות)

המטרה האקדמית: להוכיח שהוספת הקשר שיחתי מפחיתה את שיעור ההתרעות-שווא בעברית מבלי לפגוע ב-recall.

המטרה המוצרית: להציג מוצר מודגם שמבוסס על המנגנון הזה לקהל יעד של הורים ישראלים, עם מבנה עלויות היברידי המשמר רווחיות.

2. החזון

חזון: הורה ישראלי לילד בגיל 6–16 מקבל התראה אחת ביום על מקרה שבאמת דורש את תשומת לבו — לא 50 התראות שווא שהוא יילמד להתעלם מהן.

עולמנו הדיגיטלי הפך לזירה מסוכנת לילדים: בריונות מקוונת, שיח אובדני, חשיפה לתוכן מיני, סחיטה. הורים רוצים לדעת — אבל הם לא רוצים לקרוא כל הודעה של ילדם. הם רוצים מערכת שמבחינה בין משחק לאיום, בין סלנג נוער

לשנאה, בין הקנטה ידידותית לבריונות אמיתית — בעברית, מתוך ההקשר, ומסבירה כל החלטה.

זה ה-Shomer.

3 · קהל יעד / Personas

1 Persona — ההורה (המשתמש העיקרי במוצר)

שם: עינת, 42, אמא לטל (13) ולירון (10), עובדת hi-tech בתל אביב, מודעת טכנולוגית.

צרכים: - לדעת אם ילדה חשוף לסכנה דיגיטלית **בלי לנטר כל הודעה ידנית** - לקבל התראות עם **הקשר** (מה קרה, למה זה דורש תשומת לב) - לסמוך על שהמערכת לא תקרוס בעודף התראות שווא - שמירת פרטיות הילד — היא לא רוצה לקרוא כל הודעה, רק לקבל אזהרה כשיש בעיה

נקודות כאב נוכחיות: - Bark/Qustodio לא מבינים עברית → אפס תועלת - Keepers מבינים עברית "אבל סלנג של בני נוער זה אתגר שלא נפתר" (הצהרת ה-CEO) - חוסר אמון בכלים שמספרים "אולי בעיה?" כל שעותיים

איך Shomer.AI עוזרת לעינת: - מסווג עברי-ראשון, מאומן על דאטה ישראלי אמיתי + סינתטי עכשווי - כל התראה מלווה בהסבר 1-משפט ("הודעה נראית פוגענית, אבל בהקשר זה הקנטה משחקית — מסומן כירוק") - מבנה ההתראה מצמצם FP → רק התראה אחת ביום במקום 50

2 Persona — הילד (נושא הסיווג, לא משתמש ישיר)

שם: טל, 13, בת לעינת, משתמשת בוואטסאפ + אינסטגרם + דיסקורד.

מאפיינים: - שולחת/מקבלת 200~ הודעות ביום - משתמשת ב-code-switching עברית/אנגלית טבעי - חברים שלה משתמשים בסלנג שמשתנה כל חודש - מקבלת תוכן ויזואלי רב (memes, צילומי מסך, סטיקרים)

נקודות מבט שאינן ב-MVP אבל חשוב לזכור: - הילד אינו משתמש ישיר ב-Shomer.AI (פועל ברקע) - המערכת לא חוסמת הודעות (זה לא parental control קלאסי) - שיקולי פרטיות הילד מובנים בעיצוב (7 retention ימים, ללא PII בקריאות חיצוניות)

3 Persona (עתיד, לא MVP) — היועצת החינוכית

יועצות חינוכיות בבתי ספר ככלי לזיהוי תופעות בריונות בקרב תלמידים. מודגם בהגנה כ-future market expansion, אינו בנייה ב-MVP.

4.1 הפער התחרותי בעברית

מתחרה	מקור	חולשה ביחס לעברית
Bark (ארה"ב)	מובילת השוק העולמי	אנגלית בלבד — לא מסווג עברית כלל
Qustodio (ספרד)	parental control קלאסי	NLP מבוסס מילות-מפתח — חמיצת הקשר
Canopy (ארה"ב)	ראייה ממוחשבת לתוכן מיני	ממוקד עירוס בלבד, לא בריונות/שיח
Keepers (ישראל)	NLP מבוסס IBM Watson	הצהרת ה-CEO: "סלנג ישראלי נשאר אתגר"
Bosco (ישראל)	ניתוח דפוזי התנהגות	אינדיקציה איטית — אחרי הפגיעה, לא לפני

הפער: אין כלי בשוק שעושה את כל הבאים בו-זמנית — סיווג עברי איכותי, הבנת הקשר שיחתי, on-device, הסבר לכל החלטה.

4.2 הפער המחקרי

מחקר על הקשר ב-NLP toxicity מוגבל לאנגלית. הספרות החשובה:

- **Pavlopoulos et al. (2020, ACL):** הראו שהוספת הקשר תמים (concatenation נאיבי) לסיווג רעילות נותנת שיפור שולי. הציעו שדרושות שיטות מתוחכמות יותר.
- **Sap et al. (2019, ACL):** הראו ש-classifiers ללא הקשר מתייגים בטעות עד 50% מטקסט תמים בניב מיעוט. **בעיית FP חמורה.**
- **Hamad et al. (2023, AICCSA):** SinaLab Offensive-Hebrew — הקורפוס היחיד היחיד הזמין לעברית. כ-15,000 ציוצים מתויגים. אינו מטפל בהקשר שיחתי.

הפער שלנו: לא נחקרה הוספת הקשר שיחתי לסיווג בריונות בעברית, ולא קיים קורפוס שיחות עברי לבריונות. אנו מציעים להוכיח את ההשערה הראשונה ולבנות את השני.

4.3 הבעיה האמיתית של הורים

בעיית Alert Fatigue: הורים שמקבלים יותר מ-3 התראות שווא ביום נוטשים את המערכת תוך 7 ימים (מחקרי UX בתחום parental tech). לכן מערכת עם 90% accuracy אבל 20% false positive rate היא מערכת כושלת מסחרית — גם אם היא מצוינת אקדמית.

הפתרון שלנו: **שתי שכבות סיווג** — אחת מהירה וזולה (frontline), אחת עמוקה ומבוססת-הקשר (Context Agent) רק על מקרי גבול. כך FP יורד דרמטית בלי לפגוע ב-recall או בעלות.

5 · הפתרון ברמת רעיון

זרימה ברמת המשתמש

- 1. ילד שולח הודעה (טקסט או צילום מסך).
- 2. בטלפון הילד שולח לשרת ביתי מקומי Shomer.AI Client.
- 3. השרת מסווג בעברית.
- 4. מנמק על הקשר השיחה Context Agent → רק מקרי גבול.
- 5. להורה עם הסבר וציטוט push אם זוהה איום אמיתי → התראת.
- 6. אם תמים → לא קורה כלום (לא מציפים את ההורה).

העקרונות שהובילו לפתרון

עקרון	ביטוי מעשי
עברית-ראשון	מודל בסיס עברי (DictaBERT), דאטה מתויג עברית, עברית-first בכל מקום
מודע-הקשר	Context Agent שקורא 5 תורים אחרונים לפני החלטה על מקרי גבול
מסביר את עצמו	כל התראה כוללת ציטוט + הסבר 1-משפט
שומר פרטיות	קלסיפיקציה מקומית; קריאה חיצונית רק על 15% מהמקרים, ללא PII
חסכוני	הסיווג בחזית = \$0 לטוקן; LLM חיצוני רק על מקרי גבול
מציע ולא חוסם	ההורה מקבל מידע; אינו חוסם הודעות (לא parental control קלאסי)

6 · שאלת המחקר

המסמך המלא: [research_question.md](#) . תמצית להגשה :

השאלה הראשית

עד כמה הוספת ההקשר השיחתי (ההודעות הקודמות בשרשור) לסיווג בריונות בעברית מפחיתה את שיעור ההתרעות-שווא (false positives), לעומת סיווג ההודעה הבודדת במנותק — מבלי לפגוע ב-recall?

מדדים, baseline והגדרת הצלחה

- מדד ראשי: שיעור התרעות-שווא (FPR) וההפרש בינו בין שני התנאים
- מדד שמירה: recall (אסור לרדת מהותית)
- מדדי-על: precision, macro-F1, latency, cost-per-interaction
- Baseline: סיווג context-blind (אותו מודל, הודעה בודדת) + zero-shot ל-RQ1 + מספרי SinaLab

- הצלחה: ירידה מובהקת סטטיסטית ב-FPR במעבר ל-context-aware, עם recall לא-נחות, על gold set אמיתי
- הארכיטקטורה (סעיף 7 בהמשך) מממשת את הניסוי כפיצ'ר מובנה — ניתן להפעיל/לכבות את ה-Context Agent ולקבל A/B נקי לסיווג context-blind מול context-aware.


7. הארכיטקטורה (Architecture B — Locked)

הארכיטקטורה ננעלה ב-2026-05-30 לאחר Phase-0 deliberation. מסמך החלטה מלא: [architecture.decision.md](#). דיאגרמות מלאות: [architecture_diagrams.md](#).

7.1 ההחלטות שנעלו

החלטה	בחירה	רציונל קצר
וריאנט ארכיטקטורה	B — טקסט + Chat-OCR בלבד	Architecture A (multimodal) נדחתה — אין דרך למדוד את התרומה של סיווג תמונות פוגעניות בעברית, וה-RQ דורש מדידה. הסבר מלא — ראו §11 (out-of-scope).
מודל בסיס לחזית	DictaBERT-base (Hebrew encoder)	הכי טוב בעברית במחלקת ה-lightweight; רץ על CPU; fine-tune קל
צורת המערכת	Context Agent יחיד	3 סוכנים = $1.9 \sim 3 \times$ עלות עבור רווח דיוק שולי; Alert ו-Triage ניתנים להחלפה בקוד דטרמיניסטי
LLM של ה-Context Agent	GPT-4o-mini (primary), Haiku 4.5 (fallback)	אסטרטגיית test-cheap-first — נמדוד במפגש 8 ונשדרג אם צריך
OCR engine	Tesseract (heb+eng)	חינם, מקומי, מספיק טוב; קל להחליף אם נצטרך


7.2 דיאגרמה 1 — תצוגת מערכת ברמת C4 Container



על השכבה הכתומה (Gatekeeper / API Gateway): רכיב Edge שמטפל בכל בקשה נכנסת לפני הסיווג עצמו — validation, rate limiting, request logging, metrics emission — במימוש MVP זה FastAPI middleware (slowapi + structlog + prometheus-fastapi-instrumentator) שרץ in-process עם השרת. ארכיטקטונית מצויר כשכבה נפרדת כי הוא **conceptually distinct** מסיווג: מטרתו לשלוט בעומסים ולספק observability, לא לסווג. ראו רכיב §8.7.


על השכבה הסגולה (SDK): Shomer.AI SDK הוא ספרייה משותפת ב-Kotlin (ובעתיד TypeScript) שיושבת בתוך כל קליינט. הוא עוטף את החוזה של ה-FastAPI (/classify, /classify-image, /health) ופותר retries, JSON parsing, וטיפול בשגיאות במקום אחד. שני הקליינטים (ילד והורה) ימשכו אותו במקום לכתוב HTTP ידנית. ראו רכיב §8.6.

7.3 דיאגרמה 2 — Data Flow: שני מסלולי הקלט מתאחדים



המסר: OCR קורא טקסט מצילומי מסך; הטקסט נכנס לאותו pipeline. אין שני pipelines נפרדים — זו ההצדקה ההנדסית לויתור על Vision LLM.

7.4 דיאגרמה 3 — Sequence: מקרה גבול עם ה-Context Agent



מה זה מראה: הסיווג הראשוני רץ במאות מיליאניות ; רק מקרה גבול עולה ל-Context Agent ; ה-Context Agent קורא לכלים מקומיים לפני קריאה ל-LLM (חוסך טוקנים) ; ה-LLM מבסס החלטה על הקשר → במקרה הזה ההתראה נמנעה (FP-rescue). אם ה-LLM נופל → לא חוסמים אלא מסמנים לבדיקה ידנית.

8 · רכיבי המוצר (Component-level PRDs)

לכל רכיב: תפקיד · קלט · פלט · מדד הצלחה · התנהגות בכשל.

Frontline Classifier (DictaBERT-base) 8.1

מאפיין	ערך
תפקיד	סיווג מהיר וזול של כל הודעת טקסט לאחת מ-5 קטגוריות
קלט	מחרוזת טקסט עברית (עד 512 טוקנים)
פלט	{label: enum, confidence: float ∈ [0,1]}
קטגוריות (סכמת SinaLab)	abusive / hate / violence / pornographic / none-offensive
מדד הצלחה	macro-F1 ≥ 0.78 על SinaLab test split (יעד מפגש 5)
Latency	CPU על p99 < 100ms
כשל	אם המודל קורס, מחזירים {label: none, confidence: 0.5, error: true} והבקשה מסומנת לבדיקה ידנית

OCR Pipeline (Tesseract) 8.2

מאפיין	ערך
תפקיד	חילוץ טקסט עברי+אנגלי מצילומי מסך של צ'אט
קלט	תמונה (JPEG/PNG, עד 4MB)
פלט	מחרוזת טקסט (משולב he+en)
מדד הצלחה	character error rate < 15% על צילומי מסך אמיתיים (יעד מפגש 8)
Latency	p99 < 2s לתמונה בגודל הצ'אט הממוצע
כשל	אם OCR נכשל (תמונה לא קריאה), מחזיר מחרוזת ריקה והבקשה מסומנת image_unreadable: true

Context Agent (GPT-4o-mini) 8.3

מאפיין	ערך
תפקיד	reasoning על הקשר שיחה במקרי גבול ($\text{confidence} \in [0.3, 0.7]$)
קלט	הודעה נוכחית + עד 5 תורים קודמים + מטא של הילד (גיל, רגישות)
פלט	<code>{is_real_threat: bool, severity: enum, explanation: string}</code>
Tools	<code>read_conversation_history · lookup_slang · check_age_appropriateness</code>
Memory	stateless — כל קריאה אין memory persistent
Stop conditions	תשובה תקנית JSON שעוברת validation, או timeout של 5 שניות → fallback
מדד הצלחה	$\Delta\text{FPR} \geq 15$ נקודות אחוז לעומת context-blind, ללא ירידה ב-recall (יעד מפגש 8)
Latency	$p99 < 3s$ (כולל קריאה ל-API חיצוני)
כשל / Fallback	אם GPT-4o-mini לא זמין → ניסיון אחד עם Haiku 4.5. אם גם זה נכשל → מחזירים החלטה מבוססת frontline בלבד עם <code>review_flag: true</code> והתראה ל-הורה מסומנת בוויזואל

Notification Service 8.4

מאפיין	ערך
תפקיד	שליחת push notification להורה כשמזוהה איום
קלט	<code>{label, severity, explanation, quote, child_name}</code>
פלט	push notification (FCM) + רשומה ב-history של הדשבורד
פורמט	ראה open_questions.md — סעיף 3 (UX נסגר לפני מפגש 7)
מדד הצלחה	$2s >$ מההחלטה ועד הגעה לטלפון ההורה ($p99$)

Audit Log 8.5

מאפיין	ערך
תפקיד	תיעוד מלא לכל החלטה (לטובת evaluation במפגש 8)
תוכן	<code>?timestamp · message_id · classification · context_used · agent_reasoning_trace · alert_sent</code>
שמירה	7 ימים SQLite, rolling window, מקומי
שימוש	בסיס לניתוח debug, per-slice (Sap 2019), ובהמשך — feedback loop לאיסוף gold set

מאפיין	ערך
תפקיד	ספרייה משותפת שכל קליינט (אנדרואיד-ילד, אנדרואיד-הורה, web עתידי, integrations עתידיים) מייבא כדי לדבר עם FastAPI Server — במקום לכתוב HTTP ידנית בכל מקום
שפות	Kotlin (MVP — Android child + parent clients). TypeScript (Phase 9 stretch — web .dashboard)
API שהוא עוטף	POST /classify (טקסט→תיוג) · POST /classify-image (תמונה→תיוג עם OCR) · GET /model/info · GET /health
פלט (per call)	ClassificationResult(label, confidence, contextUsed, reasoningTrace?, latencyMs) — Kotlin data class / TS interface
טיפול בכשלים	retry עם exponential backoff (3 ניסיונות, 1s/2s/4s; timeout 10s; שגיאות API מתורגמות ל-Kotlin sealed class (Success / NetworkError / ServerError / ValidationError)
גישת מימוש (MVP)	Hand-written — קוד Kotlin קריא ב- /server/sdk/kotlin, סנכרון ידני עם server/app/schemas.py. עדיף על generated-from-OpenAPI ב-MVP כי קל יותר להציג ולהסביר אקדמית. החלפה ל-OpenAPI generation שמורה ל-Phase 9 אם יש 3rd-party integrations.
שימוש פנימי במוצר	Android Child Client קורא sdk.classify(text) כשהילד שולח הודעה; Android Parent Client קורא sdk.healthCheck() ומקבל push דרך FCM (לא דרך SDK).
שימוש כ-product surface	בעתיד — בתי-ספר / integrators ישראליים יוכלו לקרוא ל-Shomer.AI כשירות classification דרך אותו SDK. זה ה-API-as-a-product line מה-\$5 business plan.
מדד הצלחה (תזה)	האפליקציות עוברות מ-HTTP hand-rolled ל-SDK calls; אפס שכפול קוד HTTP בין child ל-parent clients; חוזה מתועד ב- server/sdk/README.md
מדד הצלחה (עתידי)	> 30 דקות לאינטגרציה חדשה (3rd-party מקליד import com.shomer.sdk → קורא classify/ → מקבל תוצאה)
Versioning	1.x.x — semver ב-MVP; שינוי bump major → breaking + עדכון CHANGELOG.md ב- /server/sdk
כשל	אם ה-SDK עצמו לא מצליח לעבוד (compile error, dependency conflict) הקליינט יחזור ל-hand-rolled HTTP כ-fallback זמני. החלטה זו נרשמת ב- server/sdk/README.md.

הקשר ל- /server/sdk : התיקייה הזו כיום היא placeholder עם README שמתאר את הכוונה

(server/sdk/README.md). מפגש 5 יממש גרסה ראשונית של ה-Kotlin SDK ויחליף את ה-HTTP של ה-Android

Client. הבחירה Hand-written-vs-Generated **ננעלת בזמן המימוש**.

מאפיין	ערך
תפקיד	שכבת Edge של ה-FastAPI: שליטה בעומסים (rate limiting), observability (לוגינג מובנה), metrics, request validation, export, — לא חלק מהסיווג עצמו — שכבה תפעולית שיושבת לפניו.
מיקום בארכיטקטורה	בתוך תהליך ה-FastAPI כ-MVP middleware chain; מבחינה לוגית — שכבה נפרדת בין ה-SDK ל-classification core (ראו 7.2\$)
קלט	כל בקשת HTTP נכנסת (/model/info , /health , /classify-image , /classify)
פלט (per request)	אחד מהשניים: (א) הבקשה עוברת הלאה לסיווג + emit log/metric; (ב) Too Many Requests / 429 Payload Too Large / 408 Request Timeout + emit log/metric
יכולות (MVP)	Rate limiting — 100 req/min per IP (configurable ב-env); Structured logging — כל בקשה מקבלת trace-id וצמוד אליה (endpoint, status, latency_ms, client_ip); Metrics — Prometheus; (requests/sec, p50/p95/p99 latency, error rate by endpoint); / format exposed ב- Request size limit — 10MB (תמונה); Timeout enforcement — 60s; לסיווג טקסט, 180s לסיווג תמונה (תואם את ה-Phase 2 decision).
יכולות (Phase 9 stretch)	API key auth — per-tenant key לאינטגרציות 3rd-party (לא נדרש ב-MVP כי שרת מקומי); Per-key rate limits — שונה מ-Request caching; per-IP; — אופציונלי לבקשות חוזרות; Circuit breaker — כיבוי זמני של endpoints שכושלים מעל סף
מימוש (MVP)	FastAPI middleware: slowapi (rate limit) · structlog + python-json-logger (logging) · FastAPI built-in (size/timeout) (metrics) · prometheus-fastapi-instrumentator. הכל ב-server/app/gateway.py כ-middleware chain מוגדר ב-main.py
שימוש ב-evaluation	המטריצות מ-metrics/ הן מקור-נתונים לחלק מה-NFRs במפגש 8: p99 latency, request volume, error rate. בנוסף, הלוגים ה-structured הם בסיס לניתוח per-slice של ביצועי המערכת.
מדד הצלחה	אפס בקשה עוברת לסיווג בלי לעבור 100% rate-limit-check; מהבקשות מקבלות trace-id ייחודי בלוג; metrics/ חי וניתן לסקרייפ ע"י rate-limit overage; Prometheus מחזיר 429 (לא 500)
כשל / Fallback	אם middleware נכשל ב-FastAPI init → עולה בלעדיו עם warning ב-graceful degradation log; אם rate-limit store (in-memory) נופל → fail-open (לא לחסום לגיטימיות, יעדיף false-allow על false-deny — לא הגנת אבטחה ב-MVP, רק ניטור)
NFR ייעודיים	Gateway overhead < 5ms p99 (לא מורגש על-ידי הלקוח); זיכרון > 50MB לרצועות זמן של רטרולימינג בזיכרון

למה לראות את זה כרכיב נפרד (ולא רק 'middleware של FastAPI')? - קונספטואלית — תפקידו שונה מהסיווג (operational vs functional). הפרדה במסמך מסייעת לקורא להבין אילו NFRs נמדדים איפה. - גמישות מימוש — בעתיד אפשר להחליף מ-FastAPI-middleware ל-reverse proxy חיצוני (Nginx + Lua / Traefik / Kong) בלי שינוי ב-classification core. - דיון אקדמי — מאפשר לדבר על "Edge layer" מול "core" בנפרד בהגנת המוצר.

הקשר היסטורי: רכיב זה לא היה ב-Architecture B המקורית שנעלה ב-2026-05-30 (architecture.decision.md). הוא נוסף ב-2026-05-31 כדי לשלוט בעומסי קריאות ולספק observability —

9 · דרישות לא-פונקציונליות (NFRs)

קטגוריה	דרישה	מקור / יעד
Latency (frontline)	CPU על $p99 < 100ms$	מפגש 5
Latency (Context Agent)	$p99 < 3s$	מפגש 7
Latency (end-to-end)	מהשולחן ועד התראה — $p99 < 5s$	מפגש 8
Cost/interaction	$> \$0.005$ (proposal \$11.3)	מפגש 8
Accuracy (frontline)	SinaLab על $macro-F1 \geq 0.78$	מפגש 5
Accuracy (end-to-end)	$\Delta FPR \geq 15pp$ עם recall non-inferior	מפגש 8
Privacy	אין PII בקריאה ל-LLM חיצוני; 7 retention ימים בלבד	תכנון מפגש 5
Availability (frontline)	$\leq 99\%$ (רץ מקומית, כשל = שרת ביתי נופל)	מפגש 7
Availability (Context Agent)	$\leq 95\%$ — אם פחות, ה-fallback ל-Haiku מכסה	מפגש 7
Hardware	רץ על CPU + RTX 5080 (16GB) רגיל	אילוץ קיים
Languages	עברית בלבד ב-MVP (אנגלית רק כ-OCR auxiliary לזיהוי-code-switching)	החלטת MVP

10 · KPIs

KPIs מסחריים (מתוך [business_plan.md](#)) + KPIs מחקריים :

KPIs מחקריים (יעד מפגש 8)

KPI	יעד	מדידה
ΔFPR (אם הקשר עוזר)	$\leq 15pp$ ירידה	gold set אמיתי
Recall non-inferior	$\geq 3pp$ ירידה מהבסיס	gold set אמיתי
Macro-F1 (frontline)	≤ 0.78 על SinaLab	held-out test
Inter-annotator agreement (gold set)	$\kappa \geq 0.6$	תיוג כפול
Statistical significance	$p < 0.05$ ב-McNemar	bootstrap CI

KPIs מסחריים (יעדי SOM שנה ראשונה)

KPI	יעד	מקור
משתמשים משלמים	5,000	תכנית עסקית 5\$
ARPU	40ש/חודש	תכנית עסקית 5\$
הכנסה חודשית	200,000ש	תכנית עסקית 5\$
Alert-fatigue churn (התראות שווא לפני נטישה)	> 3 ביום	מחקרי UX בתחום
paid LLM-traffic %	> 20%	תכנית עסקית 6\$

11 · Out-of-Scope (מודע ומכוון)

מתועד כ-future work, לא כפער/חולשה. ראו [open_questions.md](#) לפירוט.

מודר מ-MVP	מתי ייכלל
סיווג תמונות פוגעניות (vision LLM)	Phase 9 stretch — אם המוצר יוכיח את עצמו
ריבוי ילדים / חשבון משפחה	אחרי תזה — שינוי key אחד ב-DB
iOS support	אחרי תזה — אנדרואיד-only ב-MVP
ממשק רב-לשוני (UI אנגלי)	אחרי תזה — עברית-first
UI לניהול פרטיות (RTBF, ייצוא)	אחרי תזה — 7 retention ימים קשיחה ב-MVP
Quiet hours / DND	סגן UX לפני מפגש 7
Statistics & insights dashboard	Could-have ב-MVP, ייכנס אם זמן יאפשר
Multi-device sync	אחרי תזה

11.1 · למה במיוחד אין סיווג תמונות פוגעניות (Architecture A) — הסבר מלא

ההחלטה לוותר על Architecture A נשמעת בקלות כ"שיקול עלות", אבל הסיבה האמיתית עמוקה יותר. **שרשרת הסיבות בארבעה שלבים:**

1. אין דאטהסט עברי של תמונות פוגעניות מתויגות

↓

2. לא ניתן להעריך את המסווג בעברית באופן הוגן
(אקדמי תקני train/test split אין, benchmark אין)

↓

3. בעברית FP לא ניתן להוכיח שהפיצ'ר תורם להפחתת
(אין דרך למדידה אמפירית)

↓

דורש הוכחה מדידה – פיצ'ר לא-מדיד לא יכול להיכנס לתזה RQ-ה. 4.
(MVP-יציאה מ)

שלוש שכבות הצדקה (משולבות):

שכבה	תפקיד בהחלטה	מה זה אומר בפועל
הנדסית / דאטה	סיבה בסיסית	אין דאטה לאמן ולמדוד באופן הוגן — לא יודעים אם vision LLM פתוח (LLaVA, qwen2.5vl) עובד בעברית
אקדמית / RQ	המסנן שעשה את ההחלטה חד-משמעית	ה-RQ דורש מדידת ΔFPR בגלל הקשר שיחתי. הוספת ציר תמונה תזהם את הסיגנל הניסויי ולא תאפשר ייחוס נכון של ההשפעה.
תקציבית	משני, אבל מצטרף לסיכון	vision API יקר פי 3–10 מטקסט; אם +5% מהתעבורה תמונות — מפוצץ את התקציב. לבדו לא היה מספיק להפיל — היינו מוצאים מודל זול.

ההגיון השלם: אם הייתה לנו דאטה מצוינת — היינו מתגברים על העלות. אם לא היה לנו RQ שדורש מדידה — היינו שולחים פיצ'ר שאין לנו דרך להעריך. רק שילוב שלושת המגבלות מוביל באופן ברור ל-Architecture B.

בשורה אחת:

ויתרנו על תמונות פוגעניות כי לא ניתן למדוד את התרומה שלהן בעברית — וה-RQ דורש מדידה. הכסף היה כיכר שלישית; הוא לא היה מפיל את הפיצ'ר לבדו.

מה ייכנס בעתיד (future work): אם יקום דאטהסט עברי של תמונות פוגעניות (אקדמי או מסחרי), או אם vision LLM ב-Hebrew context יקבל benchmark פומבי — Architecture A יחזור לדיון ב-Phase 9 כשדרוג מוצרי. עד אז: לא חלק מהתזה, לא חלק מה-MVP.

הגנה תקצירית למפגש 4 (אם ד"ר סגל ישאל "למה לא תמונות?"):

"אין לנו דרך למדוד את ההשפעה של סיווג תמונות פוגעניות על שאלת המחקר. אין דאטהסט עברי, אין benchmark של vision LLM בעברית. הוצאנו זאת מ-MVP כדי לא להציג בתזה משהו שאינו ניתן להגנה אמפירית. ה-OCR לצילומי מסך נשאר — שם הטקסט בתוך התמונה כן ניתן למדידה."

⚠ מה שאני מוותרת עליו: הבטחה רב-מודאלית מההצעה המקורית. מה שאני זוכה בו: תזה ברת-הגנה עם תוצאה מדידה ומובהקת, במקום ניסוי מעורפל שלא ניתן להפריך.

סיכון	סבירות	חומרה	מיטיגציה
DictaBERT-base לא יחצה F1 0.78	בינונית	בינונית	שדרוג ל-DictaBERT-large ; אם גם זה לא — מעבר ל-DictaLM 2.0
GPT-4o-mini לא מספיק טוב ב-reasoning עברי	בינונית	בינונית	Fallback מתועד ל-Haiku 4.5 — מודדים במפגש 8 ומחליטים
Tesseract OCR גרוע על צילומי מסך אמיתיים	גבוהה	בינונית	מדידה נפרדת של OCR error rate ; אם בעיה — EasyOCR או MLKit on-device
Gold set קטן מדי (> 100 דוגמאות אמיתיות)	בינונית	גבוהה	תיוג כפול לכל דוגמה (IAA) ; השלמה עם דאטה סינתטי validated
תרחיש "image-only harms" (תוכן פוגעני בתמונה ללא טקסט)	בינונית	נמוכה	מתועד כ-future work ; ההורה יידע מה המוצר לא עושה
GDPR / רגולציה לפרטיות קטינים	נמוכה (תזה אקדמית)	גבוהה (מסחר)	7 retention ימים ; ללא PII בקריאות חיצוניות ; תיעוד עיצוב הפרטיות
Alert Fatigue למרות ה-Context Agent	נמוכה	גבוהה	מדידת FP בשלבים מוקדמים ; אם גבוה, התאמת סף ה-borderline zone

13 · שאלות פתוחות / Next Steps

המסמך המלא: [open_questions.md](#). תמצית:

#	שאלה	יעד הכרעה
1	MoSCoW לפיצ'רים — תיוג סופי	סשן ייעודי לפני מפגש 5
2	סף ביטחון להפעלת Context Agent	אמפירית במפגש 8
3	פורמט ההתראה להורה (UX)	סשן UX לפני מפגש 7
4	שמירת היסטוריית שיחות (retention)	לפני מפגש 5
5	תרחיש offline	סשן NFR לפני מפגש 7
6	Single-child / Family account	לפני מפגש 5
7	Quiet hours / DND controls	סשן UX לפני מפגש 7

ברירות מחדל זמניות מתועדות ב- [open_questions.md](#) כדי שהבנייה תוכל להתחיל מיד אחרי מפגש 4.

14 · תוכנית עבודה תקצירית (Roadmap מפגש 5 → 10)

מפגש	תוצר ראשי	תלוי ב
5	SinaLab; $F1 \geq 0.78$ על DictaBERT-base fine-tuned	אישור Architecture במפגש 4
6	סינתזת שיחות עבריות מתווגות (~500–1,000 דוגמאות); פיילוט Context Agent	מפגש 5 + סגירת Open Q 1, 4, 6
7	Context Agent מלא + 3 tools + נתיב התראה; integration end-to-end	מפגש 6 + סגירת Open Q 3, 5, 7
8	Gold set אמיתי (~150 דוגמאות); הערכה context-blind מול context-aware	מפגש 7
9	תיק שיווק (סרטון Nano-Banana, שיר SUNO); דמו מלוטש	מפגש 8
10	הגנת תזה + הגשה סופית	מפגש 9

15 · אישור והגשה (Sign-off)

המסמך הזה הוא "חוזה העבודה" (9 per slide של ד"ר סגל): מה ייבנה, איך יימדד, ואיך ייטען.

- מבקש אישור על:** 1. ☒ הארכיטקטורה שנעלה (סעיף 7) 2. ☒ ההחלטות הארכיטקטוניות וההצדקות (סעיף 7.1 + [architecture.decision.md](#)) 3. ☒ שאלת המחקר ויעדי המדידה (סעיף 6) 4. ☒ הרכיבים והגדרותיהם (סעיף 8) 5. ☒ ה-NFRs וה-KPIs (סעיפים 9, 10) 6. ☒ ה-out-of-scope המכוון (סעיף 11) 7. ☐ הסיכונים והמיטיגציות (סעיף 12) — לסקירה 8. ☐ ה-Next Steps (סעיף 13) — אישור עקרוני, פרטים בששנים ייעודיים

לאחר אישור: ה-PRD נחתם, מועלה ל-GitHub עם תג Design Frozen v0.4, והעבודה הטכנית במפגש 5 מתחילה.

ד"ר סגל — בקשה לסקירה: - האם הארכיטקטורה (B + Context Agent יחיד) משכנעת מבחינה אקדמית? - האם הוויתור על Vision LLM (Architecture A) מקובל בהתחשב במיקוד ב-RQ? - האם יש דרישה ל-3 סוכנים (Triage/Context/Alert) מההצעה המקורית שצריך להחזיר? - האם יש המלצות לעיגון נוסף ב-literature שלא כיסיתי?