

Shomer.AI — דו"ח מכין (Preparatory Report)

סטטוס: טיוטה מלאה להגשה · עודכן 2026-05-27 (שאלת מחקר מחודשת — ראו הערת המסגור) **מפגש:** 3 —
28/05/2026 · ד"ר יורם סגל מהו המסמך הזה: "חוזה העבודה" של הפרויקט (שקופית 9 של ד"ר סגל) — שבעה רכיבים
שכל אחד מהם חייב להיות ניתן-להסבר, אחרת הרכיב אינו ניתן לפיתוח, למדידה או להגנה. **מקורות הרכבה:**
[Shomer AI Project Proposal.md](#) · [research_question.md](#) · [literature_flagship.md](#) · [plan-](#)
[he/](#) · [Plan.md](#)

הערת מסגור (לקרוא לפני המפגש): ב-27/05/2026 שאלת המחקר מוקדה מחדש — מציר ה-routing הרב-
מודאלי של תמונות (RQ3 לשעבר) אל ציר ההקשר השיחתי: עד כמה הוספת ההקשר השיחתי מפחיתה התרעות-
שווא בזיהוי בריונות בעברית, בלי לפגוע ב-recall (ראו [research-framing.decision.md](#)), החלטה D-
27-05-2026 (Reframe). הציר הרב-מודאלי נשמר כמסלול משני. שתי ההכרעות הטכניות שעדיין פתוחות — מודל
בסיס (encoder/DictaBERT מול generative/QLoRA) וצורת המערכת (סוכנים מול שרת-יחיד) — מוקפאות
רשמית במפגש 4 ([plan-structure.decision.md](#)). הדו"ח מציג ארכיטקטורה ראשונית (tentative),
נקודה לאישור מול המרצה (רכיב 4 + שאלה פתוחה #1).

רכיב 1 — נושא הפרויקט (Project Frame)

Shomer.AI הוא שומר דיגיטלי המסייע להורים לזהות סיכון בתקשורת הדיגיטלית של ילדם — בריונות מקוונת,
איומים, תוכן מיני ושיח מצוקה — בעברית, מתוך השיחה וההקשר שלה (לא הודעה בודדת במנותק), ובהרצה מקומית
(on-device) שמצמצמת תלות בענן בשלב הסינון. תמיכה בתמונות היא מודאליות משנית.

ממד	תיאור
הבעיה	הכלים בשוק מבוססי-מילות-מפתח באנגלית, שופטים הודעה בודדת בלי הקשר — ולכן מציפים בהתראות שווא (Alert Fatigue) ומפספסים בריונות שמתבררת רק לאורך השיחה. הורים נוטים תוך ימים.
המשתמש	הורים לילדים בגילי 8~17 בישראל (כ-1.5M בתי אב); משנית: יועצים חינוכיים וארגוני בטיחות ילדים.
הערך	סיווג עברי-ראשון, מודע-הקשר, מוסבר (Explainable) וחסכוני — שמבדיל בין משחק/בדיחה/ציטוט לבין איום אמיתי, ובכך חותך התרעות-שווא.
מסגרת VALID	Value: כאב מוכח ל-1.5M משפחות · AI-Core: הליבה היא המסווג + סוכן-ההקשר, לא קישוט · Learned: Innovative: fine-tuning, agents, RAG, synthetic-data, cost-analysis · שימוש בהקשר שיחתי להפחתת התרעות-שווא בעברית — ציר שלא נחקר בעברית · MVP: Doable ב-10 מפגשים על חומרה אחת (RTX 5080, 16GB).

חיבור לקורס: הנושא נבחר ונעול במפגשים 1-2; דו"ח זה הוא ההסכמה ("חוזה") על מה ייבנה, איך יימדד, ואיך ייטען.

רכיב 2 — שאלת המחקר (מדד ברור)

המקור המלא: [research_question.md](#). תמצית להגשה:

שאלה ראשית (הקשר $\leftrightarrow$ false positives)

עד כמה הוספת ההקשר השיחתי (ההודעות הקודמות בשרשור) לסיווג בריונות בעברית מפחיתה את שיעור ההתרעות-שווא (false positives), לעומת סיווג ההודעה הבודדת במנותק — מבלי לפגוע ב-recall?

הניסוח עומד בדרישת שקופית 7: מה נמדד (FPR + recall), מול מה משווים (אותו מודל ללא הקשר — context-blind), ומה נחשב הצלחה (ירידת FPR מובהקת עם recall לא-נחות).

תת-שאלת יסוד (RQ1 — טקסט)

עד כמה מודל QLoRA fine-tuned בעברית מסווג בריונות, לעומת zero-shot prompting על אותו מודל בסיס:

מדדים, baseline והגדרת הצלחה

- **מדד ראשי:** שיעור התרעות-שווא (FPR) וההפרש בינו בין שני התנאים. **מדד שמירה:** recall. **מדדי-על:** precision, macro-F1.
- **Baseline:** סיווג context-blind (אותו מודל, הודעה בודדת) + zero-shot ל-RQ1 + מספרי SinaLab.
- **הצלחה:** ירידה מובהקת סטטיסטית ב-FPR במעבר ל-context-aware, עם recall לא-נחות, מוכחת על gold set אמיתי וניתנת לשחזור מ-GitHub.
- **השערות:** context-aware — H1 מפחית FPR ב- $X \leq$ נק' בלי לאבד יותר מ-Y נק' H2; recall — עיקר ההפחתה במקרי "היפוך-הקשר"; QLoRA — H3 מנצח (RQ1) zero-shot.

רכיב 3 — סקירת ספרות, מאמרי דגל, baseline ופער

המקור המלא: [literature_flagship.md](#) (ציטוטים מאומתים) + [references.bib](#).

עוגנים — כל אחד מחזיק ציר אחר

1. דאטה+משימה (עברית) — SinaLab Offensive-Hebrew (Hamad et al., 2023): סכמת התוויות + baseline טקסטואלי מבודד = בדיקת התנאי context-blind שמולו השאלה משווה.
2. הקשר — Pavlopoulos et al. (2020), ACL, "Does Context Really Matter"? : העוגן האינטלקטואלי של ציר ההקשר. הראו ששרשור-הקשר נאיבי נותן שיפור שולי — בעיה פתוחה שאנו בודקים מחדש בעברית, במיקוד FPR.

3. **התרעות-שווא** — classifiers: Davidson et al. (2019) + Sap et al. (2019) חסרי-הקשר מתייגים בטעות עד ~50% מטקסט תמים. זה הכשל שהשאלה מכוונת אליו.
4. **נתונים סינתטיים** — "Synthetic vs. Gold" (2025), ToxiGen (ACL 2022), SynBullying (2025): מתודולוגיית סינתזת שיחות מתויגות (אין דאטה עברי שיחתי).
5. **מתודולוגיה** — fine-tune: QLoRA (Dettmers et al., NeurIPS 2023): יעיל-פרמטרים על חומרה אחת.

Baseline

- **context-blind**: אותו מודל על ההודעה הבודדת בלבד. **יסוד**: zero-shot + מספרי SinaLab.

הפער שהפרויקט סוגר (התרומה)

אין מאמר עברי על הקשר שיחתי או בריונות תלוית-הקשר, ואין דאטהסט עברי של שיחות. כל עבודות ההקשר/FP הן באנגלית. הפרויקט מעביר תובנה מוכחת באנגלית אל עברית, שבה טרם נבדקה — תרומה לגיטימית, לא חזרה.

רכיב 4 — ארכיטקטורה ראשונית (Tentative — תוקפא במפגש 4)

שתי הכרעות נשארות פתוחות במכוון ([plan-structure.decision.md](#)). הצגתן כפתוחות במפגש 3 = נקודה לאישור מול המרצה (שאלה פתוחה #1).

זרימת המערכת (מה שכבר רץ end-to-end ב-POC)

```
מודל מקומי -> [Ollama :11434] --HTTP--> [FastAPI :8000] --HTTP--> [Android (Kotlin/Compose)]
|
├─ {label, confidence} → מסווג הזית: הודעה
├─ {real_threat?, הסבר} → סוכן הקשר: מקרה-גבול + תורים קודמים
└─ image router: ocr_only / vision_only / pipeline (משני)
```

- ה-POC (Step 0) הוכיח את הצינור: אפליקציית אנדרואיד קוראת לשרת מקומי ומקבלת סיווג עברי חזרה (אומת על אמולטור — Huawei P20 Pro — PASS +).
- **SDK משותף** (/server/sdk) יעלה ממעמד placeholder ל-SDK אמיתי עד מפגש 5 — דרישת קורס.

4א — מילון הטכנולוגיות: מה כל רכיב ולמה הוא מתאים לנו

כל שורה: מה זה + למה דווקא זה מתאים ל-Shomer.AI. הסימון ● =רץ כבר · =מתוכנן/מועמד · =משני.

רכיב	מה זה	למה מתאים לנו	סטטוס
Ollama	Runtime להרצת LLM-ים מקומית	מריץ את המודל על המכשיר — נתוני הילד לא עוזבים את הבית ; אפס עלות-טוקן ; הוכיח עצמו ב-POC	●
FastAPI	Framework פייתוני ל-API אסינכרוני	מהיר, מתעד OpenAPI אוטומטית (מזין את ה-SDK), פשוט לחבר בין אנדרואיד למודל	●
Qwen2.5-7B-Instruct	מודל generative פתוח רב-לשוני, 7B	רץ ב-POC ; רב-לשוני כולל עברית ; נכנס ל-16GB עם QLoRA ; ברירת-מחדל ל-fine-tune	●
DictaLM 2.0	LLM generative מותאם-עברית (מבוסס Mistral)	אומן על עברית → מורפולוגיה וסלנג עברי טובים יותר ; מועמד בסיס / השוואה (תת-שאלת RQ2)	●
DictaBERT / AlephBERT	Encoder (BERT) לעברית	קל ומהיר ; מועמד למסווג חזית זול אם נבחר נתיב encoder	●
QLoRA (PEFT + bitsandbytes)	Fine-tune יעיל ב-4-bit + LoRA adapters	מאפשר לאמן 7B על RTX 5080 יחיד (16GB) — בלי זה אין fine-tune מקומי	●
HuggingFace + TRL / Unsloth	אקוסיסטם אימון	תקן התעשייה ל-Unsloth ; QLoRA מאץ ומוריד זיכרון	●
GGUF / llama.cpp	פורמט מודל מכווץ (quantized)	ממיר את המודל המאומן לפורמט ש-Ollama מריץ מקומית ; מקשר fine-tune → deployment	●
סוכן הקשר Claude Haiku 4.5 / GPT-4o-mini + tools (+ RAG)	LLM הפועל כסוכן : קורא היסטוריית שיחה, בודק הקשר, מכריע אם זה איום אמיתי	זהו מנגנון הפחתת ה-FP — לב השאלה החדשה ; רץ רק על מקרי-גבול → זול	●
RAG + Vector store (לקסיקון סלנג)	אחזור-מבוסס-ידע	מעגן את סוכן-ההקשר בסלנג נוער ישראלי עכשווי שמשתנה כל הזמן (כלי lookup_slang)	●
Android + Kotlin + Jetpack Compose	אפליקציית חלקוח (טלפון ההורה)	נייטיב אנדרואיד, UI דקלרטיבי מודרני ; כבר בנוי	●
Tesseract OCR	מנוע OCR (טקסט מתוך תמונה)	מסלול משני — קריאת טקסט מצילומי-מסך/שלטים	●
Vision-LLM (qwen2.5vl / LLaVA-style)	LLM רב-מודאלי לתמונות	מסלול משני — סיווג תמונות אמיתיות בשיחה	●

4ב — שילובי מקורות-מידע לאימון המודל על בריונות

הבעיה : אין דאטהסט עברי של שיחות בריונות. לכן משלבים מקורות, כל אחד לתפקיד אחר :

מקור	מה זה	תפקיד באימון	מגבלה
SinaLab Offensive- Hebrew	~15.9K ציוצים עבריים מתייגים 5) (מחלקות)	בסיס המסווג הטקסטואלי + הסכמה	הודעות בודדות , ללא הקשר שיחתי
נתונים סינתטיים- שיחתיים	שיחות עברית רב-תוריות שנוצרו ב-LLM, עם מקרי היפוך-הקשר מכוונים	ליבת האימון לציר ההקשר	התוויות = של המחולל; פער מסלוג אמיתי
תרגום+עריכה מאנגלית	דאטהסטים שיחתיים אנגליים (SynBullying ועוד) מתורגמים + post- edit אנושי	augmentation — מבנה שיחה אמיתי	תרגום הורס סלנג/code- switching; תוספת בלבד
gold set אמיתי בעברית	~100–200 קטעי שיחה אמיתיים, תיוג ידני	הערכה בלבד	קטן; שיקולי אתיקה
לקסיקון סלנג עברי	מילון עגה/סלנג פוגעני עכשווי	RAG לסוכן-ההקשר (לא אימון ישיר)	תחזוקה שוטפת

השילובים (איך הם מתחברים): 1. **בסיס**: SinaLab (אמיתי, מבודד) → אימון מסווג החזית. 2. **שכבת הקשר**: סינתטי (עיקרי) + תרגום-עריכה (תוספת) → לימוד התנהגות 3. **context-aware**. **הערכה**: gold set אמיתי בלבד — העיקרון הוא **train-on-synthetic / evaluate-on-real** (אחרת המודל רק "מחקה את המחולל"). 4. **ידע חי**: לקסיקון סלנג → RAG בסוכן-ההקשר, מתעדכן בלי אימון מחדש.

⚠ **מלכודת לתעד בהגנה**: לא להשתמש באותה משפחת-מודל גם לייצור הדאטה וגם כבסיס המסווג — "אופים" פנימה אותן נקודות-עיוורון. ייצור במודל אחד, אימון/הערכה על אחר.

4ג — שתי ההכרעות הפתוחות (יוכרעו במפגש 4)

הכרעה	אופציה A	אופציה B	יוכרע
מודל בסיס	Qwen2.5-7B (רץ ב-POC) / generative + QLoRA	DictaBERT (encoder) / DictaLM 2.0	מפגש 4
צורת המערכת	שרת FastAPI יחיד → Ollama	מסווג-חזית + סוכן-הקשר (RAG+)	מפגש 4

רכיבים ניתנים-להסבר (role/input/output/metric/fallback)

- 1. **מסווג חזית** — קלט: הודעה; פלט: {label, confidence}; מדד: macro-F1; fallback: zero-shot.
- 2. **סוכן הקשר** — קלט: מקרה-גבול + k תורים קודמים; פלט: {is_real_threat, explanation, action}; מדד: **הפחתת FPR** בלי פגיעה ב-fallback; recall: התראה גולמית.
- 3. **Image track** (משני) — קלט: תמונה; פלט: label; מדד: vision_only; macro-F1; fallback:

רכיב 5 — תכנית עבודה (10 — Gantt מפגשים)

מקור: [plan-he](#) + [Plan.md](#). שלבים: A מחקר (2–1) → B תכנון (4–3) → C פיתוח (8–5) → D הצגה (9–10).

מפגש	שלב	תוצר / אבן דרך	סטטוס
0 · POC	היתכנות	אפליקציה ↔ שרת מקומי ↔ מודל — end-to-end	בוצע ✓
1	A · מחקר	נעילת נושא, GitHub, שאלת מחקר (VALID)	בעיקרו ●
2	A · מחקר	סקירת ספרות + דאטהסטים + baseline ראשון	בעיקרו ●
3	B · תכנון	דו"ח מכין · שאלת מחקר · מאמרי דגל · תכנית עסקית ← המפגש הנוכחי	בעבודה ●
4	B · תכנון	PRD מלא + הקפאת ארכיטקטורה (2 ההכרעות) + מקום הציר הרב-מודאלי	●
5	C · פיתוח	fine-tune המסווג העברי (QLoRA); לנצח את ה-baseline (RQ1)	●
6	C · פיתוח	סינתזת שיחות בריונות + מקרי היפוך-הקשר; מדידת שיפור	●
7	C · פיתוח	סוכן ההקשר (context-aware) + נתיב התמונה המשני + זרימה מלאה	●
8	C · פיתוח	gold set אמיתי + מדדים סופיים (FPR, recall, F1, latency)	●
9	D · הצגה	סרטון תדמית (Nano-Banana), שיר נושא (SUNO), מצגת	●
10	D · הצגה	הגנה + הגשה סופית	●

רכיב 6 — GitHub (ראיות עבודה)

- **GitHub הוא יומן העבודה** — כל צעד נחתם ב-commit מתויג (v0.1, v0.2, ...). מדיניות "clean run": כל צעד רץ מ-clone טרי.
- **ראיות קיימות:** היסטוריית הריפו המאוחד; תוצרי ה-POC (/integration/results/integration-1) — אמולטור (P20 Pro, PASS +); לוגי (/server/logs/) audit.
- **decision log** — כל בחירה אמיתית → /plan-docs/decisions (כולל reframe שאלת המחקר). **prompt** — [prompt-book.md](#).
- **פעולה למפגש 3:** commit של כל מסמכי המפגש + עדכון tag + README (יעד v0.2 / v0.3).

רכיב 7 — סוכני AI (חוק הזהב — חובה)

סוכני AI הם רכיב **פונקציונלי** עם תפקיד, גבולות אחריות ומדדי הצלחה — לא קישוט. שני נתיבים:

Path A — סוכן בפיתוח (חובה, פעיל כבר עכשיו)

Claude Code משמש כסוכן פיתוח: ניסוח שאלת המחקר, הרכבת דו"ח זה, כתיבת התכנית העסקית, אימות ציטוטים, ארגון התכנון. מתועד ב- [prompt-book.md](#) בפורמט 7 שדות (Goal · Context · Prompt · Model · Output · Decision · Evaluation).

Path B — סוכן במוצר (עכשיו במרכז התזה; יוכרע במפגש 4)

סוכן ההקשר הוא כעת לב התרומה — הוא המנגנון שמפחית false positives (השאלה הראשית). יוגדר כסוכן AI אמיתי: , lookup_slang , check_user_age , search_conversation_history (tools , is_game_context , ו-stop-conditions . כך נוצר product-agent שניתן למדוד (Δ FPR) ולהדגים בהגנה. אם תיבחר ארכיטקטורת שרת-יחיד — חובה להסביר כיצד הלוגיקה מודעת-ההקשר מתממשת בלעדיו.

נספח א — מיפוי לדרישות הקורס

מזהה	דרישה (שקופית)	רכיב בדו"ח זה	תוצר ראיה
REQ-RQ	שאלת מחקר מדידה (7)	רכיב 2	research_question.md
REQ-LIT	ספרות + מאמרי דגל + baseline (8)	רכיב 3	literature_flagship.md
REQ-PREP	דו"ח מכין = חוזה עבודה (9)	המסמך כולו	מסמך זה
REQ-BIZ	תכנית עסקית 6 חלקים (19–16)	— (תוצר נפרד)	business_plan.md (גרסת LaTeX רשמית: business_plan/business_plan.tex)
REQ-AGENT	סוכני AI חובה + ספר פרומפטים (4–5, 14)	רכיב 7	prompt-book.md
REQ-GITHUB	GitHub מהיום הראשון (12–10)	רכיב 6	היסטוריית הריפו

נספח ב — מה פתוח להכרעה במפגש (תקציר)

- ⚠️ אישור ה-reframe — שאלת המחקר עברה מ"ניתוב תמונות" ל"הקשר שיחתי + FP". לאשר מול המרצה; הציר הרב-מודאלי = משני.
- דו"ח מכין — ארכיטקטורה ראשונית מספיקה, או נדרשת הקפאה כבר עכשיו?
- מודל בסיס + צורת מערכת — לאשר דחייה למפגש 4.
- אסטרטגיית דאטה — סינתזה כעיקרי + gold set אמיתי; תרגום-מאנגלית כתוספת. לאשר.

הגדרת "בוצע"

- [x] כל 7 הרכיבים קיימים ומעודכנים לשאלה המחודשת.
- [x] כל רכיב מרכזי ניתן-להסבר (role/input/output/metric/fallback).

- [x] סעיף ארכיטקטורה כולל מילון טכנולוגיות (מה/למה) + שילובי מקורות-מידע.
- [x] מסומנות ההכרעות הפתוחות שיוקפאו במפגש 4 + ה-reframe לאישור.
- [] הוגש ואושר ע"י ד"ר סגל במפגש 3.