

Shomer.AI — שאלת המחקר (מותאמת לפרויקט)

סטטוס: עודכן 2026-05-27 — שאלת מחקר מחודשת (החלפה מהציר הרב-מודאלי לציר ההקשר השיחתי). ראו

מקור: plan-docs/decisions/research-framing.decision.md/.. (החלטה D-Reframe-2026-05-27).

הבחירה: דיון 2026-05-27 — אלונה בחרה את אופציה א' (הקשר $\leftrightarrow$ false positives) כשאלה הראשית. דדליין הגשה:

מפגש 3 — 28/05/2026.

שאלת המחקר הראשית

עד כמה הוספת ההקשר השיחתי (ההודעות הקודמות בשרשור) לסיווג בריונות בעברית מפחיתה את שיעור ההתרעות-שווא (false positives), לעומת סיווג ההודעה הבודדת במנותק — מבלי לפגוע ב-recall?

הבעיה האמיתית שהשאלה תוקפת: המערכת "עושה הנחות על בסיס המידע כמו שהוא", בלי להבין את הקשר השיחה — ולכן מתריעה שווא על הודעות שנראות פוגעניות אך תמימות בהקשרן (סרקזם, הקנטה ידידותית, ציטוט), ומפספסת בריונות שמתבררת רק לאור התורים הקודמים.

הניסוח עומד בדרישת שקופית 7 של ד"ר סגל: מוגדר מה נמדד (FPR + recall), מול מה משווים (אותו מודל ללא הקשר), ומה נחשב הצלחה (ירידת FPR מובהקת עם recall לא-נחות).

הניסוח המדויק (לתזה)

על דאטהסט שיחות עברי (סינתטי לאימון + gold set אמיתי קטן להערכה), משווים את אותו מסווג בשני תנאים — context-blind (הודעה בודדת) מול context-aware (הודעה + k התורים הקודמים) — ומודדים את הפרש ה-FPR וה-recall, בדגש על מקרי "היפוך-הקשר".

איך הפרויקט עונה על השאלה

רכיב בשאלה	איך Shomer.AI מספק אותו
שני התנאים blind / (aware)	אותו מודל QLoRA-fine-tuned, פעמיים : עם prompt של הודעה בודדת, ועם prompt שכולל k תורים קודמים
דאטה שיחתי בעברית	סינתזה של שיחות מתוגות (מפגש 6) — אין קורפוס עברי קיים. כולל מקרי היפוך-הקשר מכוונים. תקדים : SynBullying, ToxiGen
הערכה אמינה	gold set אמיתי של ~100–200 קטעי שיחה עברית, מתויג ידנית. מאמנים על סינתטי, מודדים על אמיתי.
מדידה	FPR, precision, recall, macro-F1 — לכל תנאי, עם מבחן מובהקות על הפרש ה-FPR
הסבר ("למה")	ניתוח שגיאות : באילו סוגי מקרים ההקשר מתקן התרעת-שווא (סרקזם / הקנטה תוך-קבוצתית / התייחסות לתור קודם)

תת-שאלות

1. יסוד (RQ1, נשמר): עד כמה מודל QLoRA fine-tuned 7B עברי מסווג בריונות, לעומת zero-shot prompting על אותו מודל בסיס?
2. אופציונלי / הרחבה (היה אופציה ב' — סומן ע"י אלונה כמורכב): מהו ה-Pareto frontier בין precision (FP) ל-recall כפונקציה של גודל ההקשר k (כמה תורים אחורה)?
3. אופציונלי / הרחבה (היה אופציה ג' — סומן ע"י אלונה כמורכב): באילו סוגי מקרים בלשניים (סרקזם, אירוניה, הקנטה תוך-קבוצתית) ההקשר מתקן התרעות-שווא, ובאילו לא?
4. משני (ציר רב-מודאלי — ירד מ"ראשי"): כשהשיחה כוללת תמונה, איזו אסטרטגיית טיפול בתמונה תורמת לסיווג? (נשמר כמסלול אופציונלי; הכרעה במפגש 4.)

השערות (מדידות)

- H1: סיווג context-aware יפחית את ה-FPR ב- $X \leq$ נקודות אחוז לעומת context-blind, מבלי להוריד את ה-recall ביותר מ-Y נקודות. (לקבע X, Y לפני מפגש 8.)
- H2: עיקר הפחתת ה-FPR מרוכז במקרי "היפוך-הקשר" — הודעות שנראות פוגעניות במנותק אך תמימות בהקשרן.
- H3 (יסוד): QLoRA fine-tune ינצח zero-shot ב-macro-F1 על משימת הבסיס (RQ1).

מדדים, baseline והגדרת הצלחה

- **מדד ראשי:** שיעור התרעות-שווא (FPR) — וההפרש בינו בין שני התנאים. **מדד שמירה:** recall (אסור לרדת מהותית). **מדדי-על:** precision, macro-F1.
- **Baseline (התנאי המשווה):** סיווג context-blind — אותו מודל בדיוק, על ההודעה הבודדת בלבד. (ועוד baseline-יסוד: zero-shot, ל-RQ1).
- **הצלחה:** ירידה מובהקת סטטיסטית ב-FPR במעבר ל-context-aware, עם recall לא-נחות (non-inferiority), מוכחת על gold set אמיתי וניתנת לשחזור מ-GitHub.

חיבור לדרישות הקורס

- שקופית 7 (שאלת מחקר מחזיקה את הכול): שאלה · מדד (FPR/recall) · ניסוי (blind מול aware) · מסקנה.
- מסגרת VALID — ה-AI-Core הוא המסווג; החידוש (Innovative) הוא שימוש בהקשר שיחתי להפחתת התרעות-שווא בעברית — ציר שלא נחקר בעברית.
- מזינה את הדו"ח המכין (משימה 3) ואת מאמרי הדגל (משימה 2 — ראו literature_flagship.md).

פעולות פתוחות

- ⚠️ **שינוי ספין מהותי:** השאלה עברה מ"ניתוב תמונות" ל"הקשר שיחתי". יש לתאם את קטלוג ה-RQs (./plan-docs/research_questions.md) ואת תוכנית ה-POC (Phase 2/4 בנויות סביב תמונות) — ההכרעה הסופית במפגש 4. **לאשר מול המרצה במפגש 3.**
- להכריע על אסטרטגיית הדאטה: סינתזה כעיקרי + gold set אמיתי. (טרם נסגר אם להוסיף תרגום-מאנגלית כ-augmentation).
- לקבע ספים מספריים ל- $H1(X, Y)$ לפני מפגש 8.
- ethics: איסוף ה-gold set האמיתי — מקורות ציבוריים, זהירות עם קטינים.