

Shomer.AI — ספר פרומפטים (Prompt Book)

מטרה: תיעוד כל שימוש משמעותי בסוכן AI בפרויקט — דרישת הקורס (חוק הזהב + ספר פרומפטים, שקופיות 4–5, Path A. (סוכן ככלי פיתוח): הרשומות כאן מתעדות את Claude Code כסוכן פיתוח לאורך הפרויקט — ניסוח, הרכבה, אימות, ארגון. זהו חלק ממנדט הסוכנים (ראו [preparatory_report.md](#) רכיב 7). **פורמט:** 7 שדות לכל רשומה — Goal · Context · Prompt · Model · Output · Evaluation · Decision.

הערה: הפרומפטים מצוטטים בתמצית. הניסוח המלא נמצא בהיסטוריית השיחה ובהגדרות הסוכנים שהורצו.

רשומה 1 — הרכבת תוצרי מפגש 3 (במקביל, מבוססת-סוכנים)

שדה	תוכן
Goal (מטרה)	להכין את ארבעת תוצרי מפגש 3 — דו"ח מכין, שאלת מחקר, מאמרי דגל, תכנית עסקית — בחלון של 4 ימים.
Context (הקשר)	מקורות קיימים: , research_questions.he.md , plan-he/ , Proposal related_work.he.md , ה-decision log. דרישת "הרכבה והתאמה", לא יצירה מאפס.
Prompt (פרומפט)	"בוא נמשיך לבצע את ההכנות לקראת מחר 28-05 ... להכין דו"ח מכין מפורט, למצוא שאלת מחקר ... להכין תכנית עסקית ולהכין מאמרי דגל ... במקביל על ידי skills מתאימים לכל משימה."
Model (מודל)	orchestrator — Claude Opus 4.7 (1M context) ; שני (general-purpose) sub-agents במקביל ברקע.
Output (פלט)	חלוקה: סוכן A → תכנית עסקית LaTeX ; סוכן B → אימות ציטוטים ; ה-thread הראשי → דו"ח מכין + ספר פרומפטים.
Evaluation (הערכה)	זוהתה מראש מתיחות מסגור (Proposal מול docs) ואומתה מול ה-decision log לפני כתיבה — נמנע תוצר סותר.
Decision (החלטה)	✓ התקבל. לעקוב אחרי המסגור המתועד (RQ3 ראשית + ארכיטקטורה פתוחה למפגש 4), לא לפתוח החלטות נעולות.

רשומה 2 — אימות ציטוטים של מאמרי הדגל

שדה	תוכן
Goal (מטרה)	לאמת ולתקן את הציטוטים של מאמרי הדגל לפני ההגשה ; לפתור את ה- ⚠️ על ציטוט SinaLab.
Context (הקשר)	literature_flagship.md סימן את ציטוט SinaLab כטעון-אימות ; "Jarrar et al". "היה ניחוש. המסגור (שני עוגנים) נעול ואסור לשנותו.
Prompt (פרומפט)	"Verify and format citations ... resolve the SinaLab ⚠️ ... never fabricate a citation, arXiv id, or" ".DOI ... do NOT change the framing
Model (מודל)	Claude (general-purpose sub-agent) + WebSearch/WebFetch (arXiv, IEEE Xplore, ACL Anthology, GitHub)
Output (פלט)	ציטוט SinaLab מתוקן : Hamad, N., Jarrar, M., Khalilia, M., & Nashif, N. (2023). "Offensive DictaLM + תיקון Hebrew Corpus and Detection using BERT." AICCSA. arXiv:2309.02724 . references.bib + יצירת (Shmidman et al., 2024, arXiv: 2407.07080) 2.0
Evaluation (הערכה)	מאומת מול arXiv/IEEE/ACL ה-DOI של SinaLab נגזר מ-10479258 doc וסומן לאימות-סופי (IEEE החזיר 401). שום ציטוט לא הומצא.
Decision (החלטה)	✅ התקבל ועודכן in-place. נותר : אימות סופי של ה-DOI לפני ההגשה הסופית.

רשומה 3 — כתיבת תכנית עסקית ב-LaTeX

שדה	תוכן
Goal (מטרה)	תכנית עסקית 6 סעיפים ב-LaTeX (עברית RTL), מוכנה לקימפול ב-Overleaf (XeLaTeX).
Context (הקשר)	מקורות: <code>Proposal \$2.3/\$3/\$4/\$9.1/\$11.3 + plan-he/03</code> . אין מנוע LaTeX מקומי → חייב להיות Overleaf-ready. דרישה: לסמן מספרים לא-ממוקרים [למקור], לא להמציא.
Prompt (פרומפט)	<i>Author a 6-section business plan in LaTeX ... XeLaTeX + polyglossia + bidi ... token-economics".No invented citations.</i> [למקור] <i>formula + worked example ... mark unsourced numbers</i>
Model (מודל)	Claude (general-purpose sub-agent) + WebSearch (גודל שוק, דמוגרפיה CBS, תמחור מתחרים, תמחור טוקנים).
Output (פלט)	<code>docs/business_plan/business_plan.tex + README.md</code> עם הוראות קימפול ורשימת מספרים טעוני-מקור. (ראו דוח הסוכן בסיום הריצה).
Evaluation (הערכה)	אומתו בוויב (footnotes): גודל שוק ~2.25M~; $CAGR \sim 9.8-12.25\%$; $\$1.55B \rightarrow \$1.74B$ משפחות בישראל (CBS); תמחור Bark/Qustodio/Canopy; מחירי טוקנים Claude Haiku/GPT-4o-mini/Gemini Flash; נשארו [למקור]: קוהורט SAM מדויק (6–16 עם סמארטפון), SOM (40ש / 5,000 — יעד פנימי), מחירי Keepers/Bosco, והנחות נפח ה-token-economics. שום ציטוט לא הומצא.
Decision (החלטה)	טיוטה מובנית להצגה במפגש 3; מספרי token-economics ממוקרים-במלואם נדחים לאחרי המפגש (ראו <code>next-meeting-prep</code>).

רשומה 4 — הרכבת חבילת התכן המלאה (מפגש 4, 10 LLDs במקביל)

שדה	תוכן
Goal (מטרה)	לייצר חבילת תכן מלאה לפני מימוש — Low-Level Design לכל מודול + גיבוי משימות JSON — מוכנה לאישור מפגש 4.
Context (הקשר)	PRD v1.0 + ארכיטקטורה B נעולים. נדרש תכן מפורט (תבנית 11 סעיפים) לכל מודול, עם דגש / OOP ports-and-adapters ו-swappability מלאה (החלפת Context-Agent / DictaBERT / OCR בלי לגעת בשרת).
Prompt (פרומפט)	"Use product manager + project organizer agents to analyze the PRD and produce one Low-Level Design per module ... JSON tasks per module; everything under a design/ folder." + "Every component must be swappable ... without changing the server. Strong OOP"
Model (מודל)	3 + Claude Opus (orchestrator) סוכני product-strategist במקביל (/ AI-core / client-edge .orchestration).
Output (פלט)	9 קבצי design.md (~5,470 שורות) + docs/design/README.md (עקרונות ports-and-adapters) + Interface boundary\$ "2.5" בכל tasks.json + 9 tasks_index.json + LLD (124 משימות, מורחב מאוחר יותר ל-144).
Evaluation (הערכה)	זוהו מראש פערים לתיקון (non_offensive ↔ none-offensive , חוסר , train_dictabert.py refactor של OcrBackend ; כל ה-JSON אומת לפרסור ול-cross-references.
Decision (החלטה)	✓ דפוס composition-root נעול: רק lifespan server/app/main.py () בונה adapters קונקרטיים. ה-README הוא מקור-האמת למי-מייבא-את-מי.

רשומה 5 — סקירת ארכיטקטורה + פתרון 3 חוסמים (מפגש 4)

שדה	תוכן
Goal (מטרה)	לוודא שה-LLDs מכסים את כל הפונקציונליות הנדרשת, ולזהות שאלות פתוחות לפני תחילת מימוש.
Context (הקשר)	9 LLDs קיימים; נדרש coverage matrix מול PRD \$1-\$15 ובדיקת concerns חוצי-מערכת (trace_id, (A/B switch, privacy, retention, label consistency, confidence direction).
Prompt (פרומפט)	"Review the architecture design and charts and verify the LLD architecture contains all necessary" functionality. Are there open questions to resolve before tasks execution?" → "Yes [fix the 3 blockers]"
Model (מודל)	סוכן architecture-reviewer (סקירה) + סוכן product-strategist (LLD למודול audit_log).
Output (פלט)	docs/design/review.md (486 שורות), verdict Conditional Ready · 3 Blockers · 7 Important , 5 Nice . 3 החוסמים נפתרו: LLD audit_log/ — G-01 חדש (758 שורות + 14 משימות, סכמת SQLite 5 טבלאות); G-02 — תווית נעולה G-03 ; non_offensive — תיקון polarity ב-decide_inner_ + מטריצת בדיקה 6 שורות. 144 → Backlog משימות.
Evaluation (הערכה)	כל חוסם סומן  RESOLVED ב-review.md כלוח-מצב חי; באג G-03 (is_offensive=False,) confidence=0.92 היה מנותב בטעות ל-ALERT_DIRECT נתפס ונמנע.
Decision (החלטה)	 אושר; 7 בעיות (G-04...G-14) Important נדחו במכוון לשבוע 1 של מימוש.

רשומה 6 — בניית צינור השרת המודולרי (מפגש 3, 5 agents במקביל)

שדה	תוכן
Goal (מטרה)	לבנות את מודולי השרת — classifier (DictaBERT), OCR, Context Agent — מאחורי ה-Protocols, חי end-to-end.
Context (הקשר)	ממשקי Protocol מוגדרים; שכבת ה-foundation (4 + schemas.py קבצי protocol.py) הוכנה ידנית מראש כדי לאפשר עבודה מקבילית בלי התנגשויות.
Prompt (פרומפט)	<i>"Can we start building the server modules: classifier, OCR, Context Agent — using backend-".developer + ml-developer in parallel ... now that we have the Protocol interfaces"</i>
Model (מודל)	ai-researcher-developer (classifier) + 2× backend-developer (ocr, context_agent) במקביל.
Output (פלט)	ocr (~1,400, 45 tests; + (tests; Ollama+HuggingFace+Stub adapters 57, שורות, classifier (~2,150~) Tesseract extraction-only) + context_agent (~2,350, 70 tests; Mock+OpenAI+Anthropic clients + LlmRouter + SqliteTokenManager) + InMemoryAuditStore stop-gap + main.py → "שלום עולם" composition root. 172 tests passing ; smoke test POST /classify . non_offensive
Evaluation (הערכה)	smoke test ירוק דרך Ollama אמיתי; כל החלפת adapter = env-var flip יחיד. (CLASSIFIER_MODEL_VERSION)
Decision (החלטה)	✓ ה-composition-root + ייבוא Protocol-only בין מודולים הם כעת אמיתיים בקוד, לא רק במסמכים.

רשומה 7 — נעילת ארכיטקטורת הרשת של DictaBERT (מפגש 5)

שדה	תוכן
Goal (מטרה)	לתכנן בקפידה, שכבה-אחר-שכבה, את ארכיטקטורת הרשת (DictaBERT + שכבות חדשות) לסיווג תוכן פוגעני — לפני אימון.
Context (הקשר)	ה-LLD של ה-classifier החזיק רק היפר-פרמטרים בסיסיים (lr, batch, epochs) — לא ארכיטקטורה מלאה ולא בחירת loss.
Prompt (פרומפט)	<i>Plan the full NN architecture carefully — do we have it? Use ai-educator-architect + ai-researcher-developer." + "What ways do we have to change data for best results — accurate and fast?"</i>
Model (מודל)	סוכן ai-educator-architect .
Output (פלט)	docs/concepts/dictabert_classifier_architecture.md (903 שורות, 12 סעיפים): MLP head ([CLS]→Dropout→Linear(768→256)→GELU→Dropout→Linear(256→5)), Focal Loss $\gamma=2$ + $\alpha=class_weights$, $\epsilon=0.05$ label smoothing, AdamW+cosine, 5 epochs BF16, fallback chain, dictabert_data_techniques.md + data contract. §9 (~500 שורות) עם §8 combination-safety.
Evaluation (הערכה)	השוו 5 חלופות ארכיטקטורה (Vanilla/Multi-task/Hierarchical/DAPT) ; $\epsilon=0.05$ (ולא 0.1) הומלץ בגלל השילוב עם §8 Focal; תיעד 4 סיכוני stacking עם מיטיגציות.
Decision (החלטה)	הארכיטקטורה נעולה — המסמך עצמו הוא רשומת ההחלטה (עם נימוק, חלופות וציטוטים). הערה: param count אמיתי התברר כ-184.3M (לא ~110M) עקב אוצר-המילים העברי.

רשומה 8 — זרימת השרת המלאה (מפגש 6, 4 מודולים במקביל)

שדה	תוכן
Goal (מטרה)	לחבר כל מודול מתוכנן Triage / Alerts / Gatekeeper / SqliteAuditStore — end-to-end — בלי אימון DictaBERT ובלי שינוי קלט ה-classifier.
Context (הקשר)	הצינור הריץ Gatekeeper, Alerts חסרו ; classifier→inline-triage→CA→in-memory audit (ALERT_DIRECT היה inert), Triage עצמאי, ו-SQLite persistence.
Prompt (פרומפט)	<i>"Build the full flow, then the SDK, create tasks, and implement with backend-developer + ai-researcher-developer agents"</i>
Model (מודל)	3 × ai-researcher-developer + 1 × backend-developer במקביל.
Output (פלט)	triage (45 tests) + alerts/ LogNotifier (105) + gateway.py (37) + SqliteAuditStore (23); main.py v0.6.0-fullflow (retention sweeper, LogNotifier dispatch, register_gateway(), conversation persistence); debug SDK (dev_client replay / inspect_audit / load_test) + 7 integration tests. 384 fast tests pass ; live demo 10/10, 6 sent + 2 rate_limited alerts persisted
Evaluation (הערכה)	4 באגים התגלו בבדיקות ותוקנו: record_agent_trace לא נקרא, trace_id לא הועבר ל-CA, קונסולת Windows cp1252 הפילה שורת log עברית של alerts.sent (→ אכיפת UTF-8 stdio), crash על dict ב-inspect_audit.
Decision (החלטה)	LogNotifier D1 ברירת-מחדל (+ FCM כצעד הבא); D2 כלי-debug ב-Python קודם (+ sdk- Kotlin); cli אחריו; D3 אופציונלי לזיכרון-שיחה אמיתי.

רשומה 9 — Context Agent על LLM אמיתי (Gemini) + + baseline accuracy test console (מפגש 6)

שדה	תוכן
Goal (מטרה)	להעלות את ה-Context Agent על LLM אמיתי, למדוד את ה-accuracy הבסיסי של המערכת, ולבנות קונסולת בדיקה ידנית ידידותית.
Context (הקשר)	ה-CA רץ עד כה על Mock דטרמיניסטי (כל הסלמה → "לא איום" → silent); לא היה מדד accuracy בסיסי ולא כלי בדיקה ידני נוח (הקלדת עברית מתהפכת ב-Windows terminal).
Prompt (פרומפט)	<i>Build a friendly UI for manual full-flow testing ... add Gemini support for the Context Agent; " and run the OCR/text eval data through the pipeline to measure baseline accuracy as a PDF (no "data changes / no training)</i>
Model (מודל)	gemini-2.5-flash — GeminiClient (primary, endpoint) תואם-OpenAI + haiku-4.5 (fallback). הערכה דרך השרת החי.
Output (פלט)	scripts/test_console.py (python-bidi + sample-picker) RTL via ממוספר, per-session GeminiClient + scripts/eval_accuracy.py . Baseline: + (audit.db + server.log TEXT 69.5% / IMAGE 66.3% 5-class, ~80% binary; hate recall ≈0.10. PDF: docs/meeting6_accuracy_report.pdf
Evaluation (הערכה)	image ≈ text → ה-classifier הוא צוואר-הבקבוק, לא ה-OCR — מוטיבציה כמותית חזקה ל-fine-tune. תוקנו 3 באגי bring-up (model 2.0→2.5, פסי ``thinking", json " שגדע JSON) + באג key-string + מפתחות env. שגויים.
Decision (החלטה)	Gemini > OpenAI — plan-docs/decisions/gemini-context-agent.decision.md עדיפות — Anthropic > (מפתח ראשון primary, שני Mock, fallback משלים).

תבנית לרשומה חדשה (להעתיק)

שדה	תוכן
Goal	
Context	
Prompt	
Model	
Output	
Evaluation	
Decision	